

**IMPLEMENTASI *BUSINESS INTELLIGENCE* BERBASIS
DATA WAREHOUSE UNTUK SISTEM REKOMENDASI
KECOCOKAN TANAMAN BERDASARKAN
KONDISI CUACA MENGGUNAKAN
*ALGORITMA RANDOM FOREST***

LAPORAN PROJEK AKHIR

**Oleh :
Kelompok 2**

Taufik Ramadhani	2409116001
Adella Putri	2409116006
Dwi Pebriyanto Pradana	2409116012



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2026**

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, kami dapat menyelesaikan laporan proyek mata kuliah Business Intelligence yang berjudul **“Implementasi Business Intelligence Berbasis Data Warehouse untuk Sistem Rekomendasi Kecocokan Tanaman Berdasarkan Kondisi Cuaca Menggunakan Algoritma Random Forest”** dengan baik.

Laporan ini disusun sebagai bagian dari tugas akhir/proyek pada mata kuliah Business Intelligence. Proyek ini mengintegrasikan proses Data Engineering, khususnya melalui tahapan Extract, Transform, Load (ETL) dan pembangunan Data Warehouse, serta proses Data Science melalui penerapan algoritma Random Forest. Sistem yang dikembangkan bertujuan untuk memberikan rekomendasi kecocokan tanaman berdasarkan parameter lingkungan, seperti kondisi cuaca dan kondisi tanah.

Melalui proyek ini, kami berupaya membangun dasar sistem analisis Business Intelligence yang mampu membantu proses pengambilan keputusan berbasis data, khususnya dalam bidang pertanian. Selain itu, sistem ini juga dirancang agar dapat dikembangkan lebih lanjut ke dalam bentuk aplikasi berbasis web yang informatif, interaktif, dan mudah digunakan oleh pengguna.

Kami menyadari bahwa penyusunan laporan ini masih memiliki kekurangan, baik dari segi penulisan, penyajian data, maupun pengembangan sistem. Oleh karena itu, kami sangat mengharapkan kritik dan saran yang membangun agar laporan dan proyek ini dapat menjadi lebih baik di masa mendatang.

Akhir kata, kami mengucapkan terima kasih kepada dosen pengampu mata kuliah Business Intelligence atas bimbingan dan arahan yang telah diberikan. Kami juga mengucapkan terima kasih kepada semua pihak yang telah membantu dalam proses penyusunan laporan dan pengembangan proyek ini.

Semoga laporan ini dapat memberikan manfaat, baik bagi penulis maupun pembaca, serta dapat menjadi referensi dalam penerapan Business Intelligence, Data Warehouse, dan Machine Learning pada sistem rekomendasi berbasis data lingkungan.

Samarinda, 12 Mei 2026

Kelompok 2

DAFTAR ISI

	halaman
KATA PENGANTAR.....	i
DAFTAR ISI	ii
DAFTAR TABEL	iv
DAFTAR GAMBAR.....	v
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Tujuan Penelitian.....	3
1.4. Manfaat Penelitian.....	4
BAB II PERACANGAN SISTEM.....	5
2.1. Tinjauan Pustaka	5
2.1.1. <i>Business Intelligence</i>	5
2.1.2. <i>Data Warehouse</i> dan <i>Star schema</i>	6
2.1.3. Proses ETL (<i>Extract, Transform, Load</i>)	7
2.1.4. <i>Random Forest Classifier</i>	8
2.2. Sumber Data	9
2.3. Asitektur Sistem	12
2.4. Perancangan <i>Data Warehouse</i>	13
2.5. Perancangan Model <i>Machine Learning</i>	15
2.6. Perancangan Antarmuka Website	18
BAB III METODOLOGI PENELITIAN	20
3.1. Gambaran Umum Sistem yang Dikembangkan	20
3.2. Hasil Implementasi <i>Data Warehouse</i>	21
3.2.1. Struktur dan Isi Tabel Dimensi	21
3.2.2. Struktur dan Isi Tabel Fakta	22
3.2.3. Validasi Proses ETL	23
3.3. Hasil Implementasi Model <i>Machine Learning</i>	24
3.3.1. Performa Model pada Data Latih dan Data Uji	24
3.3.2. Analisis Fitur Penting (<i>Feature Importance</i>)	25
3.3.3. Penyimpanan dan Pemuatan Model	26
3.4. Hasil Integrasi API BMKG	26
3.4.1. Mekanisme Pengambilan Data Cuaca	26
3.4.2. Proses Inferensi <i>Real-time</i>	27
3.5. Hasil dan Pembahasan Antarmuka Website	28
3.5.1. Halaman Utama dan Form Input	28
3.5.2. Halaman Hasil Rekomendasi	29
3.5.3. <i>Dashboard</i> Visualisasi Data	30
3.6. Pengujian Sistem	30
3.6.1. Pengujian Fungsional	30
3.6.2. Pengujian Validasi Rekomendasi	31
3.7. Pembahasan Kelebihan dan Keterbatasan Sistem	32
3.7.1. Kelebihan Sistem	32
3.7.2. Keterbatasan Sistem	33
BAB IV IMPLEMENTASI DAN TAMPILAN PROGRAM	34
4.1. Lingkungan Implementasi	34
4.2. Tampilan Halaman Beranda (Homepage)	35
4.3. Tampilan Halaman Cuaca	38
4.4. Tampilan Halaman Analisis Tanaman	41

4.5.	Tampilan Halaman Data Historis	44
4.6.	Tampilan Halaman Laporan	46
4.7.	Tampilan Halaman Masuk (Login)	49
4.8.	Tampilan Halaman Daftar (Register)	50
4.9.	Tampilan Executive Dashboard.....	51
BAB V	KESIMPULAN DAN SARAN.....	57
5.1.	Kesimpulan	57
5.2.	Saran	57
DAFTAR PUSTAKA.....		59

DAFTAR TABEL

	halaman
Tabel 2.1. Struktur Tabel dalam Data Warehouse Star schema.....	14
Tabel 2.2. Hasil Evaluasi Model Random Forest pada Data Uji	17

DAFTAR GAMBAR

	halaman
Gambar 4.1. Tampilan Halaman Beranda AgroSense	36
Gambar 4.2. Tampilan Halaman Cuaca AgroSense	39
Gambar 4.3. Tampilan Halaman Analisis Tanaman AgroSense.....	42
Gambar 4.4. Tampilan Halaman Data Historis AgroSense	45
Gambar 4.5. Tampilan Halaman Laporan AgroSense	47
Gambar 4.6. Tampilan Halaman Masuk (Login) AgroSense	49
Gambar 4.7. Tampilan Halaman Daftar (Register) AgroSense	50
Gambar 4.8. Tampilan Executive Dashboard Tab Performance Overview	52
Gambar 4.9. Tampilan Executive Dashboard Tab Performance Overview	53
Gambar 4.10. Tampilan Executive Dashboard Tab Data Explorer.....	54
Gambar 4.11. Tampilan Executive Dashboard Tab Data Explorer.....	55
Gambar 4.12. Tampilan Executive Dashboard Tab User Management.....	56

BAB I

PENDAHULUAN

1.1. Latar Belakang

Sektor perkebunan merupakan tulang punggung perekonomian Indonesia, khususnya bagi daerah-daerah yang bertumpu pada hasil bumi sebagai sumber pendapatan utama masyarakatnya. Kontribusi sektor perkebunan terhadap Produk Domestik Bruto (PDB) nasional terus menunjukkan angka yang signifikan, terutama di kawasan luar Jawa seperti Kalimantan, Sulawesi, dan Sumatera. Namun demikian, produktivitas perkebunan di Indonesia masih menghadapi berbagai tantangan struktural yang belum sepenuhnya terselesaikan, salah satunya adalah keterbatasan akses petani terhadap informasi yang akurat dan berbasis data mengenai kondisi lingkungan yang sesuai untuk pertumbuhan tanaman tertentu (Kementerian Perkebunan Republik Indonesia, 2022).

Pemilihan jenis tanaman yang tidak sesuai dengan kondisi cuaca dan tanah di suatu wilayah merupakan penyebab utama kegagalan panen yang dialami oleh para petani. Menurut *Food and Agriculture Organization of the United Nations* (FAO, 2021), lebih dari 30% kerugian hasil perkebunan global disebabkan oleh ketidaksesuaian antara jenis tanaman yang ditanam dengan kondisi iklim dan lingkungan setempat. Di Indonesia, permasalahan serupa semakin diperparah oleh dampak perubahan iklim yang mengakibatkan ketidakstabilan pola cuaca, seperti pergeseran musim hujan dan kemarau yang tidak dapat diprediksi secara konvensional. Kondisi ini menuntut adanya sebuah sistem yang mampu mengintegrasikan data cuaca secara *real-time* dengan pengetahuan perkebunan berbasis data historis untuk memberikan rekomendasi yang tepat kepada para petani maupun pemangku kepentingan di sektor agrikultur.

Perkembangan teknologi informasi, khususnya di bidang *Business Intelligence* (BI) dan *Data Warehouse*, membuka peluang besar untuk menTransformasi cara pengambilan keputusan di sektor perkebunan. *Business Intelligence* didefinisikan sebagai serangkaian teknik dan alat yang digunakan untuk mengubah data mentah menjadi informasi yang bermakna dan berguna bagi tujuan analisis bisnis (Negash, 2004). Teknologi ini telah terbukti berhasil meningkatkan efisiensi pengambilan keputusan di berbagai industri,

mulai dari keuangan, kesehatan, hingga perdagangan. Penerapan BI dalam konteks perkebunan, yang dikenal dengan istilah *Agricultural Intelligence* atau *Smart Farming*, kini semakin mendapat perhatian para peneliti dan pengembang sistem karena potensinya yang sangat besar dalam meningkatkan produktivitas dan ketahanan pangan (Kamilaris et al., 2017).

Data Warehouse sebagai fondasi dari sistem *Business Intelligence* memainkan peran krusial dalam mengintegrasikan berbagai sumber data yang heterogen menjadi satu repositori terpusat yang terstruktur dan siap dianalisis. Konsep *Data Warehouse* pertama kali diperkenalkan oleh Inmon (1992), yang mendefinisikannya sebagai kumpulan data berorientasi subjek, terintegrasi, *time-variant*, dan non-volatile yang mendukung proses pengambilan keputusan manajemen. Dalam konteks sistem ini, *Data Warehouse* dirancang menggunakan skema bintang (*star schema*) yang mengintegrasikan data historis perkebunan dari dataset publik Kaggle dengan data cuaca *real-time* yang diperoleh dari *Application Programming Interface* (API) Badan Meteorologi, Klimatologi, dan Geofisika (BMKG). Integrasi ini memungkinkan sistem untuk menganalisis keterkaitan antara kondisi cuaca terkini dengan karakteristik tanaman yang ada dalam basis data historis.

Selain pendekatan *Data Warehouse*, sistem yang dikembangkan dalam penelitian ini juga memanfaatkan teknik *Machine Learning*, khususnya algoritma *Random Forest Classifier*, untuk membangun model prediktif yang mampu mengklasifikasikan kecocokan tanaman berdasarkan parameter cuaca dan tanah. *Random Forest* merupakan metode *ensemble learning* yang bekerja dengan membangun sejumlah besar pohon keputusan pada saat pelatihan dan mengeluarkan kelas yang merupakan modus dari kelas-kelas yang dihasilkan oleh pohon-pohon individual tersebut (Breiman, 2001). Algoritma ini dipilih karena kemampuannya dalam menangani data berdimensi tinggi, ketahanannya terhadap *overfitting*, serta performa yang konsisten dan akurat dalam berbagai permasalahan klasifikasi. Dalam pengujian yang dilakukan pada dataset tanaman yang mencakup delapan jenis komoditas perkebunan, model yang dibangun berhasil mencapai akurasi sebesar 80.625%, yang menunjukkan bahwa model ini memiliki kemampuan prediktif yang cukup handal untuk digunakan dalam sistem rekomendasi perkebunan.

Website yang dikembangkan dalam proyek ini berfungsi sebagai antarmuka pengguna yang menghubungkan seluruh komponen sistem, mulai dari *Data Warehouse*,

model *Machine Learning*, hingga API cuaca BMKG. Pengguna dapat memasukkan lokasi daerah serta jenis tanaman yang ingin ditanam seperti cabai, kentang, tomat, atau kangkung dan sistem akan secara otomatis menganalisis kondisi cuaca saat ini serta prediksi cuaca ke depan, meliputi suhu, curah hujan, dan kelembapan, untuk memberikan rekomendasi apakah tanaman tersebut cocok ditanam di daerah tersebut. Sistem juga menampilkan saran alternatif tanaman yang lebih sesuai, tingkat risiko terhadap kondisi cuaca, serta visualisasi data perkebunan dan cuaca melalui *dashboard* interaktif. Pendekatan ini sejalan dengan konsep *decision support system* (DSS) yang bertujuan memberikan informasi yang relevan dan tepat waktu kepada pengambil keputusan, baik di tingkat petani individual maupun pemangku kepentingan kebijakan perkebunan (Turban et al., 2011).

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, terdapat beberapa permasalahan mendasar yang menjadi landasan pengembangan sistem ini

1. Bagaimana mengatasi hambatan integrasi data perkebunan dan cuaca yang saat ini masih tersebar dalam berbagai format dan struktur yang berbeda?
2. Bagaimana merancang arsitektur *Data Warehouse* dengan *star schema* yang mampu menampung data historis dan data *real-time* dari BMKG?
3. Bagaimana membangun model *Machine Learning* dengan algoritma *Random Forest* yang memiliki tingkat akurasi tinggi dalam memprediksi kecocokan tanaman?
4. Bagaimana mengembangkan platform *Business Intelligence* berbasis web yang mampu menyajikan hasil analitik data dalam bentuk visualisasi interaktif yang mudah digunakan oleh pemangku kepentingan?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan dari pengembangan sistem ini adalah

Tujuan Utama

Merancang dan mengimplementasikan platform *Business Intelligence* berbasis *Data Warehouse* untuk memberikan rekomendasi kecocokan tanaman

secara cerdas berdasarkan data cuaca *real-time* dan historis.

Tujuan Khusus

1. Merancang arsitektur *Data Warehouse* menggunakan *star schema* yang mengintegrasikan dimensi tanaman, cuaca, tanah, dan tabel fakta prediksi.
2. Melakukan proses *Extract, Transform, Load* (ETL) terhadap dataset perkebunan untuk memastikan kualitas data yang akan diolah.
3. Membangun model *Machine Learning* dengan algoritma *Random Forest Classifier* menggunakan variabel suhu, kelembapan, dan *ph* tanah.
4. Mengintegrasikan model prediksi dengan API cuaca BMKG ke dalam antarmuka web yang interaktif dan *user-friendly*.

1.4. Manfaat Penelitian

Manfaat yang diharapkan dari pengembangan sistem ini dapat ditinjau dari beberapa perspektif sebagai berikut:

1. Perspektif Praktis

Memberikan kemudahan akses bagi petani dan penyuluh untuk mendapatkan rekomendasi tanaman berbasis data ilmiah dan cuaca terkini, sehingga meminimalkan risiko gagal panen serta mengoptimalkan hasil produksi.

2. Perspektif Manajerial dan Kebijakan

Membantu instansi terkait seperti Dinas Perkebunan dalam memantau kondisi wilayah secara simultan guna mengambil kebijakan yang tepat sasaran, seperti perencanaan distribusi pupuk dan benih yang berbasis data (*data-driven decision making*).

3. Perspektif Akademis dan Ilmiah

Memberikan kontribusi nyata dalam implementasi konsep *Data Warehouse*, ETL, dan *Machine Learning* pada domain perkebunan, serta memperkaya literatur mengenai integrasi data statis dan dinamis (API *real-time*) dalam sistem *Agricultural Intelligence*.

BAB II

PERACANGAN SISTEM

2.1. Tinjauan Pustaka

2.1.1. Business Intelligence

Business Intelligence (BI) merupakan seperangkat metodologi, proses, arsitektur, dan teknologi yang mengubah data mentah menjadi informasi yang bermakna dan berguna untuk tujuan bisnis. Menurut Negash dan Gray (2008), *Business Intelligence* adalah sistem yang menggabungkan pengumpulan data, penyimpanan data, dan manajemen pengetahuan dengan analisis untuk mengevaluasi informasi bisnis yang kompleks sehingga dapat mendukung pengambilan keputusan yang lebih baik. Dalam perkembangannya, BI tidak hanya digunakan di lingkungan bisnis komersial, tetapi juga telah diadopsi secara luas di berbagai sektor termasuk kesehatan, pendidikan, pemerintahan, dan perkebunan untuk membantu pemangku kepentingan memahami tren, pola, dan anomali dalam data yang tersedia.

Komponen utama dalam sistem *Business Intelligence* mencakup sumber data, proses ETL, *Data Warehouse*, lapisan analitik, dan antarmuka visualisasi. Sumber data dapat berupa basis data transaksional, *file* terstruktur seperti CSV, maupun sumber eksternal seperti API web. Lapisan analitik dalam BI mencakup berbagai teknik seperti *Online Analytical Processing* (OLAP), *data mining*, dan *Machine Learning* yang memungkinkan pengguna untuk melakukan eksplorasi data secara multidimensional. Eckerson (2010) mengklasifikasikan kematangan BI dalam suatu organisasi ke dalam lima tingkatan, yaitu dari tingkat pelaporan standar hingga tingkat prediktif yang mampu mengantisipasi kejadian masa depan berdasarkan pola historis. Sistem yang dikembangkan dalam penelitian ini berada pada tingkatan prediktif, karena menggunakan model *Machine Learning* untuk memprediksi kecocokan tanaman berdasarkan kondisi cuaca.

Penerapan *Business Intelligence* di sektor perkebunan, yang sering disebut sebagai *Agricultural Business Intelligence* atau *Smart Agriculture*, telah menjadi topik penelitian yang semakin berkembang dalam satu dekade terakhir. Wolfert et al. (2017) dalam studinya mengenai Big Data in *Smart Farming* menyatakan bahwa integrasi data

dari berbagai sumber termasuk sensor lingkungan, citra satelit, dan data cuaca ke dalam platform analitik terpusat memiliki potensi untuk merevolusi cara petani dan pemangku kebijakan dalam membuat keputusan perkebunan. Penelitian tersebut menegaskan bahwa keberhasilan sistem BI perkebunan sangat bergantung pada kualitas data yang digunakan, kemampuan sistem untuk memproses data secara *real-time*, dan kemudahan antarmuka yang disajikan kepada pengguna akhir. Ketiga aspek inilah yang menjadi landasan utama dalam perancangan sistem yang disajikan dalam laporan ini.

2.1.2. *Data Warehouse* dan *Star schema*

Data Warehouse adalah suatu sistem penyimpanan data terpusat yang dirancang khusus untuk mendukung kegiatan analitik dan pelaporan bisnis, berbeda dari basis data transaksional yang dioptimalkan untuk operasi baca-tulis yang cepat. Kimball dan Ross (2013) mendefinisikan *Data Warehouse* sebagai salinan data transaksi yang secara spesifik terstruktur untuk kueri dan analisis. Karakteristik fundamental dari *Data Warehouse* yang pertama kali dirumuskan oleh Inmon (1992) mencakup empat sifat utama, yaitu berorientasi subjek (*subject-oriented*), terintegrasi (*integrated*), tidak berubah setelah dimasukkan (*non-volatile*), dan bervariasi terhadap waktu (*time-variant*). Keempat sifat ini menjadikan *Data Warehouse* sebagai fondasi yang ideal untuk sistem *Business Intelligence* yang membutuhkan konsistensi dan keandalan data dalam jangka panjang.

Star schema merupakan salah satu teknik pemodelan data yang paling umum digunakan dalam perancangan *Data Warehouse*. Struktur *star schema* terdiri dari satu tabel fakta sentral yang terhubung langsung dengan beberapa tabel dimensi yang mengelilinginya, membentuk pola seperti bintang jika divisualisasikan. Tabel fakta menyimpan data terukur atau metrik bisnis beserta kunci asing yang merujuk ke tabel dimensi, sedangkan tabel dimensi menyimpan atribut deskriptif yang digunakan untuk memfilter, mengelompokkan, dan memberi label pada data di tabel fakta (Kimball, 1996). Dalam konteks sistem yang dikembangkan, tabel fakta bernama *fact_prediction* berisi 7.904 rekaman data yang masing-masing menghubungkan satu entitas tanaman, satu kondisi cuaca, dan satu kondisi tanah melalui kunci asing *crop_id*, *weather_id*, dan *soil_id*.

Keunggulan *star schema* dibandingkan model data lainnya seperti *snowflake schema* terletak pada kesederhanaan struktur dan performa kueri yang lebih baik. Karena

tabel dimensi tidak dinormalisasi lebih lanjut, jumlah operasi join yang diperlukan untuk mengeksekusi kueri analitik berkurang secara signifikan. Hal ini sangat menguntungkan dalam sistem yang membutuhkan respons cepat terhadap permintaan analitik seperti sistem rekomendasi *real-time*. Según Adamson (2010), *star schema* lebih mudah dipahami oleh pengguna bisnis non-teknis dan lebih mudah dioptimasi oleh mesin basis data, sehingga menjadikannya pilihan yang paling praktis untuk sebagian besar implementasi *Data Warehouse* skala menengah. Desain *star schema* yang digunakan dalam sistem ini memiliki tiga tabel dimensi dan satu tabel fakta yang secara kolektif memungkinkan analisis multidimensional terhadap data perkebunan.

2.1.3. Proses ETL (*Extract, Transform, Load*)

Extract, Transform, Load (ETL) adalah proses tiga tahap yang menjadi jantung dari setiap implementasi *Data Warehouse*. Tahap pertama, *Extract*, melibatkan pengambilan data dari berbagai sumber yang heterogen, baik berupa *file* CSV, basis data relasional, API web, maupun format data lainnya. Tahap kedua, *Transform*, merupakan tahap paling kompleks dan kritis di mana data yang telah diekstrak mengalami serangkaian operasi pembersihan, standardisasi, validasi, dan pengayaan untuk memastikan kualitas dan konsistensi data sebelum dimuat ke dalam *Data Warehouse*. Tahap ketiga, *Load*, adalah proses pemuatan data yang telah diTransformasi ke dalam struktur *Data Warehouse* yang telah dirancang (Vassiliadis, 2009).

Kualitas data yang dihasilkan oleh proses ETL memiliki dampak langsung terhadap kehandalan sistem *Business Intelligence* secara keseluruhan. Prinsip yang sering dikutip dalam komunitas data *engineering* adalah *garbage in, garbage out*, yang berarti bahwa model analitik atau *Machine Learning* sebaik apapun tidak akan menghasilkan *output* yang berguna jika data masukan yang digunakannya mengandung inkonsistensi, duplikasi, atau nilai yang hilang. Menurut Rahm dan Do (2000), permasalahan kualitas data dalam proses ETL dapat dikategorikan ke dalam dua kelompok besar, yaitu permasalahan tingkat skema (*schema-level problems*) seperti perbedaan format dan representasi data, serta permasalahan tingkat instansi (*instance-level problems*) seperti nilai yang hilang, duplikat, dan outlier. Kedua kategori permasalahan ini ditangani secara sistematis dalam proses ETL yang dilakukan pada dataset perkebunan dalam penelitian ini.

Dalam konteks sistem yang dikembangkan, proses ETL dilakukan terhadap dua

dataset sumber, yaitu *Crop_recommendation.csv* yang memuat 2.200 rekaman dari 22 jenis tanaman dengan delapan atribut, dan *crop_yield_dataset.csv* yang memuat 36.520 rekaman dari berbagai jenis tanaman dengan dua belas atribut termasuk data historis hasil panen. Dari kedua dataset tersebut, proses seleksi dan *Transformasi* menghasilkan dataset bersih bernama *crop_dataset.csv* dengan 7.904 rekaman yang hanya mempertahankan empat atribut yang relevan dengan tujuan sistem, yaitu *crop_name*, *temperature*, *humidity*, dan *ph*. Proses *Transformasi* juga mencakup *filtering* untuk mempertahankan hanya delapan jenis tanaman yang terdapat di kedua dataset, serta penyesuaian skala dan format data agar konsisten di seluruh rekaman.

2.1.4. *Random Forest Classifier*

Random Forest adalah sebuah algoritma *Machine Learning* berbasis *ensemble* yang bekerja dengan cara membangun sejumlah besar pohon keputusan (*decision trees*) secara acak dan paralel selama fase pelatihan, kemudian menggabungkan prediksi dari seluruh pohon tersebut melalui mekanisme voting mayoritas untuk menghasilkan prediksi akhir pada masalah klasifikasi. Algoritma ini pertama kali diperkenalkan secara formal oleh Breiman (2001) dan sejak saat itu menjadi salah satu algoritma klasifikasi yang paling banyak digunakan dalam berbagai aplikasi praktis karena kemampuannya mengatasi masalah *overfitting* yang sering terjadi pada algoritma pohon keputusan tunggal. Dua mekanisme kunci yang membuat *Random Forest* efektif adalah *bagging* (*bootstrap aggregating*) untuk pemilihan sampel pelatihan, dan *random feature selection* untuk pemilihan atribut pada setiap percabangan pohon.

Keunggulan *Random Forest* dalam konteks klasifikasi perkebunan telah dibuktikan oleh berbagai penelitian sebelumnya. Liakos et al. (2018) dalam tinjauan sistematis mengenai penerapan *Machine Learning* di sektor perkebunan menemukan bahwa *Random Forest* secara konsisten memberikan performa yang tinggi dalam berbagai tugas prediksi perkebunan, termasuk klasifikasi penyakit tanaman, prediksi hasil panen, dan pemetaan kondisi tanah. Keunggulan ini disebabkan oleh kemampuan *Random Forest* dalam menangani data dengan dimensi tinggi tanpa memerlukan seleksi fitur yang ekstensif, serta ketahanannya terhadap *noise* dan *outlier* dalam data. Selain itu, *Random Forest* mampu menghasilkan ukuran kepentingan fitur (*feature importance*) yang memberikan wawasan berharga mengenai variabel mana yang paling berpengaruh terhadap prediksi yang dihasilkan.

Dalam implementasi sistem ini, model *Random Forest* dilatih menggunakan tiga fitur masukan, yaitu *temperature* (suhu dalam derajat Celsius), *humidity* (kelembapan udara dalam persen), dan *ph* (tingkat keasaman tanah), untuk memprediksi jenis tanaman yang paling sesuai dari delapan kelas yang tersedia. Model dibangun menggunakan pustaka *scikit-learn* dengan konfigurasi *n_estimators* sebesar 100 pohon dan *random_state* sebesar 42 untuk memastikan reproduktibilitas hasil. Dataset dibagi dengan rasio 80 persen untuk data latih dan 20 persen untuk data uji menggunakan metode *train_test_split*, menghasilkan 6.323 sampel latih dan 1.581 sampel uji. Sebelum dilatih, seluruh fitur numerik dinormalisasi menggunakan *StandardScaler* untuk memastikan bahwa perbedaan skala antar fitur tidak mempengaruhi proses pembelajaran model.

2.2. Sumber Data

2.2.1. Dataset Kaggle: Crop Recommendation

Materi Dataset pertama yang digunakan sebagai sumber data dalam penelitian ini adalah *Crop Recommendation Dataset* yang diperoleh dari platform Kaggle, sebuah komunitas data *science* dan repositori dataset publik yang dikelola oleh Google. Dataset ini memuat 2.200 rekaman data perkebunan yang mencakup 22 jenis tanaman, dengan setiap rekaman berisi delapan atribut terukur, yaitu kandungan nitrogen (N), fosfor (P), dan kalium (K) dalam tanah dalam satuan miligram per kilogram, suhu udara (*temperature*) dalam derajat Celsius, kelembapan relatif udara (*humidity*) dalam persen, tingkat keasaman tanah (*ph*) dalam skala *ph*, curah hujan (*rainfall*) dalam milimeter, dan label kelas tanaman. Dataset ini dirancang khusus untuk mendukung pengembangan sistem rekomendasi tanaman berbasis *Machine Learning* dan telah digunakan secara luas dalam berbagai penelitian di bidang *Agricultural Intelligence*.

Distribusi data dalam *Crop Recommendation Dataset* bersifat seimbang, dengan setiap jenis tanaman diwakili oleh 100 rekaman, sehingga total keseluruhan rekaman adalah 2.200. Rentang nilai atribut *temperature* berkisar antara 8,83 hingga 43,68 derajat Celsius dengan rata-rata 25,62 derajat Celsius, sedangkan atribut *humidity* memiliki rentang 14,26 hingga 99,98 persen dengan rata-rata 71,48 persen. Atribut *ph* berada dalam rentang 3,50 hingga 9,94 dengan rata-rata 6,47, mencerminkan variasi kondisi keasaman tanah yang cukup luas. Setelah melalui proses *filtering* untuk mempertahankan hanya delapan jenis tanaman yang relevan dengan sistem, yaitu *maize*, *mungbean*, *banana*,

watermelon, orange, papaya, tomato, dan potato, jumlah rekaman yang diambil dari dataset ini adalah sebanyak 800 rekaman, dengan masing-masing tanaman diwakili oleh 100 rekaman.

Proses seleksi tanaman dari dataset ini didasarkan pada dua kriteria utama. Kriteria pertama, yaitu ketersediaan tanaman yang sama dalam dataset kedua sehingga memungkinkan penggabungan data. Kriteria kedua adalah relevansi tanaman tersebut dengan konteks perkebunan tropis di Indonesia, di mana kedelapan tanaman yang dipilih merupakan komoditas perkebunan yang umum dibudidayakan di wilayah Indonesia, khususnya di Kalimantan Timur. Pada tahap ini juga dilakukan verifikasi bahwa tidak terdapat *missing values* maupun duplikat dalam rekaman yang dipilih, sehingga data yang masuk ke dalam proses *Transformasi* selanjutnya dapat dijamin kualitasnya.

2.2.2. Dataset Kaggle: Crop Yield Dataset

Materi Dataset kedua yang digunakan adalah *Crop Yield Dataset* dari Kaggle yang memuat 36.520 rekaman data historis perkebunan dengan rentang waktu dari tahun 2014 hingga tahun data terakhir tersedia. Dataset ini memiliki dua belas atribut yang lebih komprehensif dibandingkan dataset pertama, meliputi *Date* (tanggal pencatatan), *Crop_Type* (jenis tanaman), *Soil_Type* (jenis tanah: *Peaty, Loamy, Sandy, Clay, Silty*), *Soil_ph* (keasaman tanah), *Temperature* (suhu udara), *Humidity* (kelembapan), *Wind_Speed* (kecepatan angin), *N* (nitrogen), *P* (fosfor), *K* (kalium), *Crop_Yield* (hasil panen dalam satuan ton per hektar), dan *Soil_Quality* (indeks kualitas tanah). Keberagaman atribut dalam dataset ini memungkinkan analisis yang lebih mendalam mengenai faktor-faktor yang mempengaruhi produktivitas tanaman.

Dari 36.520 rekaman dalam dataset ini, dilakukan proses *filtering* untuk mempertahankan hanya rekaman yang berkaitan dengan delapan jenis tanaman yang telah ditetapkan dalam *scope* sistem, yaitu *tomato* dan *potato* yang masing-masing memiliki jumlah rekaman terbesar dalam dataset ini. Kedua tanaman tersebut berkontribusi masing-masing sebanyak 3.652 rekaman ke dalam dataset bersih akhir, sehingga total kontribusi dari dataset kedua ini adalah 7.304 rekaman. Besarnya jumlah rekaman untuk *tomato* dan *potato* dalam dataset ini disebabkan oleh frekuensi pencatatan historis yang lebih tinggi dibandingkan jenis tanaman lainnya, yang mencerminkan pentingnya kedua komoditas tersebut dalam produksi perkebunan global. Atribut yang dipertahankan dari dataset ini untuk keperluan integrasi adalah *temperature, humidity, dan ph* tanah,

sedangkan atribut lainnya tidak digunakan karena tidak dapat diperoleh secara *real-time* dari API BMKG.

Penggabungan data dari kedua dataset di atas menghasilkan dataset bersih final dengan total 7.904 rekaman yang mencakup delapan jenis tanaman dengan distribusi yang tidak seimbang. Tanaman *tomato* dan *potato* masing-masing memiliki 3.652 rekaman, sedangkan enam tanaman lainnya masing-masing memiliki 100 rekaman. Ketidakseimbangan distribusi kelas ini kemudian ditangani dalam tahap *preprocessing Machine Learning* menggunakan teknik *balancing* dengan metode *undersampling*, di mana setiap kelas di-*sampling* sebanyak 100 rekaman untuk memastikan bahwa model tidak mengalami bias ke arah kelas mayoritas. Teknik *balancing* ini penting untuk memastikan bahwa model *Random Forest* yang dihasilkan memiliki kemampuan prediksi yang adil dan akurat untuk seluruh delapan jenis tanaman.

2.2.3. API Cuaca *Real-time* BMKG

Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) Republik Indonesia menyediakan layanan *Application Programming Interface* (API) publik yang memungkinkan aplikasi pihak ketiga untuk mengakses data cuaca terkini dan prakiraan cuaca untuk berbagai wilayah di Indonesia secara programatik. API BMKG menyediakan data dalam format JSON yang terstruktur dan dapat diakses tanpa autentikasi berbayar, menjadikannya sumber data cuaca *real-time* yang ideal untuk sistem berbasis web dengan sumber daya terbatas. Data yang tersedia melalui API BMKG mencakup suhu udara minimum dan maksimum, kelembapan relatif, kecepatan dan arah angin, kondisi cuaca umum (cerah, berawan, hujan), serta prakiraan cuaca untuk beberapa hari ke depan.

Integrasi API BMKG ke dalam sistem *Business Intelligence* perkebunan ini memberikan dimensi temporal yang krusial, yaitu kemampuan sistem untuk merespons kondisi cuaca aktual yang sedang terjadi di lokasi yang diinputkan pengguna, bukan hanya mengandalkan data historis yang statis. Setiap kali pengguna memasukkan lokasi dan jenis tanaman yang ingin ditanam, sistem secara otomatis melakukan permintaan ke *endpoint* API BMKG untuk mendapatkan data suhu dan kelembapan terkini di daerah tersebut. Nilai-nilai ini kemudian diteruskan sebagai masukan ke model *Machine Learning* yang telah dilatih, sehingga rekomendasi yang diberikan kepada pengguna selalu mencerminkan kondisi lingkungan yang aktual dan relevan pada saat permintaan dilakukan.

Pendekatan integrasi data *real-time* dengan model prediktif statis ini merupakan pola arsitektur yang dikenal sebagai *Online Prediction* atau *Real-time Inference* dalam terminologi *Machine Learning Engineering*. Kleppmann (2017) dalam bukunya *Designing Data-Intensive Applications* menjelaskan bahwa pola ini memiliki keunggulan dalam hal responsivitas dan relevansi prediksi, namun memerlukan desain sistem yang hati-hati untuk memastikan bahwa latensi panggilan API eksternal tidak berdampak negatif terhadap pengalaman pengguna. Dalam sistem ini, manajemen latensi ditangani melalui implementasi mekanisme *caching* sederhana pada lapisan aplikasi web, sehingga permintaan cuaca untuk lokasi yang sama dalam rentang waktu tertentu tidak perlu melakukan panggilan API berulang ke server BMKG.

2.3. Asitektur Sistem

Arsitektur sistem *Business Intelligence* yang dikembangkan dalam penelitian ini terdiri dari empat lapisan utama yang saling terhubung dan bekerja secara sinergis. Lapisan pertama adalah lapisan sumber data (*data source layer*) yang mencakup dua dataset Kaggle dalam format CSV dan API cuaca *real-time* BMKG. Lapisan kedua adalah lapisan pemrosesan ETL (*ETL processing layer*) yang bertanggung jawab untuk mengekstrak, membersihkan, mentransformasi, dan memuat data dari sumber ke dalam *Data Warehouse*. Lapisan ketiga adalah lapisan *Data Warehouse* dan analitik (*warehouse and analytics layer*) yang menyimpan data dalam skema *star schema* serta menghosting model *Machine Learning* yang telah dilatih. Lapisan keempat adalah lapisan presentasi (*presentation layer*) yang merupakan antarmuka web berbasis browser yang digunakan oleh pengguna akhir untuk berinteraksi dengan sistem.

Alur data dalam sistem ini mengikuti pola yang disebut sebagai Lambda Architecture secara parsial, di mana terdapat jalur pemrosesan *batch* untuk data historis dan jalur pemrosesan *real-time* untuk data cuaca terkini, yang kemudian diintegrasikan pada lapisan analitik sebelum hasilnya disajikan kepada pengguna. Jalur *batch* dimulai dari proses ETL terhadap dataset Kaggle yang menghasilkan tabel-tabel dalam *Data Warehouse*, kemudian digunakan untuk melatih model *Random Forest* yang disimpan dalam format serialisasi .pkl menggunakan pustaka joblib. Jalur *real-time* dimulai dari permintaan pengguna melalui antarmuka web, yang memicu panggilan ke API BMKG untuk mendapatkan data cuaca terkini, yang kemudian dikombinasikan dengan *input ph*

tanah dari pengguna untuk diproses oleh model *Machine Learning* yang telah terlatih.

Komponen penyimpanan dalam sistem ini mencakup tiga *file* model *Machine Learning* yang saling melengkapi. Pertama adalah *crop_model.pkl* yang berukuran sekitar 2,86 MB dan menyimpan model *Random Forest* yang telah dilatih dengan 100 estimator. Kedua adalah *label_encoder.pkl* yang menyimpan pemetaan antara label numerik dan nama tanaman asli, memungkinkan sistem untuk mengkonversi *output* numerik model kembali menjadi nama tanaman yang dapat dibaca oleh pengguna. Ketiga adalah *scaler.pkl* yang menyimpan parameter *StandardScaler* yang digunakan selama pelatihan, sehingga data *input* baru dari pengguna dapat dinormalisasi dengan cara yang persis sama sebelum diproses oleh model, memastikan konsistensi antara distribusi data latih dan data inferensi.

2.4. Perancangan *Data Warehouse*

2.4.1. Skema *Star schema*

Perancangan *Data Warehouse* dalam sistem ini menggunakan pendekatan *star schema* yang terdiri dari satu tabel fakta sentral dan tiga tabel dimensi yang mengitarinya. Pendekatan ini dipilih berdasarkan rekomendasi Kimball dan Ross (2013) yang menyatakan bahwa *star schema* adalah struktur yang paling optimal untuk sistem *Business Intelligence* yang mengutamakan kecepatan kueri analitik dan kemudahan pemahaman oleh pengguna bisnis. Seluruh relasi antar tabel diimplementasikan menggunakan kunci asing (*foreign key*) yang menghubungkan tabel fakta dengan masing-masing tabel dimensi, memungkinkan operasi join yang efisien saat dilakukan analisis kueri.

Tabel fakta bernama *fact_prediction* merupakan pusat dari skema ini dan memuat 7.904 rekaman yang merepresentasikan setiap kombinasi unik dari tanaman, kondisi cuaca, dan kondisi tanah yang terdapat dalam dataset bersih. Tabel ini memiliki empat kolom, yaitu *prediction_id* sebagai kunci primer dengan tipe integer *auto-increment*, *crop_id* sebagai kunci asing yang merujuk ke tabel *dim_crop*, *weather_id* sebagai kunci asing yang merujuk ke tabel *dim_weather*, dan *soil_id* sebagai kunci asing yang merujuk ke tabel *dim_soil*. Desain ini memungkinkan sistem untuk melakukan analisis lintas dimensi dengan mudah, misalnya untuk menemukan kondisi cuaca dan tanah yang paling sering diasosiasikan dengan tanaman tertentu, atau untuk mengidentifikasi rentang suhu

dan kelembapan yang optimal bagi masing-masing komoditas.

Ketiga tabel dimensi dalam sistem ini masing-masing merepresentasikan aspek yang berbeda dari konteks perkebunan. Tabel *dim_crop* memuat delapan rekaman yang merepresentasikan kedelapan jenis tanaman yang ditangani sistem, dengan dua kolom yaitu *crop_id* (kunci primer) dan *crop_name* (nama tanaman). Tabel *dim_weather* memuat 7.904 rekaman kondisi cuaca unik, dengan tiga kolom yaitu *weather_id*, *temperature*, dan *humidity*. Tabel *dim_soil* memuat 605 rekaman kondisi tanah unik yang dibedakan berdasarkan nilai *ph*, dengan dua kolom yaitu *soil_id* dan *ph*. Jumlah rekaman dalam *dim_soil* yang lebih kecil dibandingkan *dim_weather* mencerminkan fakta bahwa terdapat lebih banyak variasi kondisi cuaca dibandingkan kondisi tanah yang terdokumentasi dalam dataset yang digunakan.

Tabel 2.1. Struktur Tabel dalam *Data Warehouse Star schema*

No	Nama Tabel	Kolom	Tipe Kolom	Keterangan
1.	<i>fact_prediction</i>	<i>prediction_id</i>	INTEGER (PK)	Kunci primer unik
2.		<i>crop_id</i>	INTEGER (FK)	Rujukan ke <i>dim_crop</i>
3.		<i>weather_id</i>	INTEGER (FK)	Rujukan ke <i>dim_weather</i>
4.		<i>soil_id</i>	INTEGER (FK)	Rujukan ke <i>dim_soil</i>
5.	<i>dim_crop</i>	<i>crop_id</i>	INTEGER (PK)	Kunci primer tanaman
6.		<i>crop_name</i>	VARCHAR	Nama jenis tanaman
7.	<i>dim_weather</i>	<i>weather_id</i>	INTEGER (PK)	Kunci primer cuaca
8.		<i>temperature</i>	FLOAT	Suhu udara (Celsius)
9.		<i>humidity</i>	FLOAT	Kelembapan udara (%)
10.	<i>dim_soil</i>	<i>soil_id</i>	INTEGER (PK)	Kunci primer tanah
11.		<i>ph</i>	FLOAT	Keasaman tanah (<i>ph</i>)

2.4.2. Proses ETL secara Detail

Tahap *Extract* merupakan tahap pertama dalam proses ETL di mana data diambil dari dua sumber dataset Kaggle dalam format CSV. Proses ekstraksi dilakukan menggunakan pustaka *pandas* dalam bahasa pemrograman *Python*, yang memungkinkan pembacaan *file* CSV secara efisien bahkan untuk dataset berukuran besar seperti *crop_yield_dataset.csv* yang memuat 36.520 rekaman. Pada tahap ini, kedua dataset dibaca sepenuhnya ke dalam memori sebagai objek *DataFrame*, kemudian dilakukan

inspeksi awal terhadap struktur data, tipe kolom, dan distribusi nilai untuk mengidentifikasi potensi permasalahan kualitas data sebelum tahap *Transformasi* dimulai. Verifikasi awal menunjukkan bahwa tidak terdapat *missing values* dalam kolom-kolom yang akan digunakan, sehingga proses dapat langsung dilanjutkan ke tahap transformasi tanpa memerlukan penanganan nilai yang hilang.

Tahap *Transform* mencakup serangkaian operasi yang mengubah data mentah dari kedua sumber menjadi format yang seragam dan siap dimuat ke dalam *Data Warehouse*. Operasi transformasi yang dilakukan meliputi: pertama, seleksi kolom di mana hanya kolom *crop_name* (atau label pada dataset pertama dan *Crop_Type* pada dataset kedua), *temperature* (atau *Temperature*), *humidity* (atau *Humidity*), dan *ph* (atau *Soil_ph*) yang dipertahankan, sementara kolom lainnya seperti N, P, K, *rainfall*, *Wind_Speed*, *Crop_Yield*, *Soil_Quality*, *Date*, dan *Soil_Type* diabaikan karena tidak relevan dengan model prediksi yang dibangun. Kedua, standardisasi nama kolom dilakukan untuk memastikan konsistensi penamaan antara data dari kedua sumber. Ketiga, *filtering* dilakukan untuk mempertahankan hanya delapan jenis tanaman target.

Tahap *Load* merupakan tahap terakhir di mana data yang telah melalui proses *Transformasi* dimuat ke dalam struktur *Data Warehouse* yang telah dirancang sebelumnya. Proses *Loading* dilakukan secara bertahap, dimulai dari pembuatan tabel dimensi. Tabel *dim_crop* dibuat dengan menetapkan ID unik untuk masing-masing dari delapan tanaman secara manual. Tabel *dim_weather* dibuat dengan mengekstrak kolom *temperature* dan *humidity* dari dataset bersih beserta ID auto-increment. Tabel *dim_soil* dibuat dengan mengekstrak nilai *ph* unik dari dataset bersih. Terakhir, tabel *fact_prediction* dibuat dengan mengintegrasikan ketiga dimensi tersebut melalui proses pemetaan nilai dari dataset bersih ke ID yang sesuai di masing-masing tabel dimensi. Seluruh tabel kemudian disimpan dalam format CSV terstruktur yang dapat dimuat ke dalam sistem manajemen basis data relasional maupun digunakan langsung oleh aplikasi web.

2.5. Perancangan Model *Machine Learning*

2.5.1. *Preprocessing* Data

Preprocessing data merupakan langkah kritis sebelum model *Machine Learning* dapat dilatih, karena kualitas dan bentuk data yang digunakan secara langsung

mempengaruhi kemampuan model dalam mempelajari pola yang ada. Tahap pertama dalam *preprocessing* adalah *balancing* dataset untuk mengatasi ketidakseimbangan distribusi kelas yang terjadi akibat proses penggabungan data dari dua sumber. Dari total 7.904 rekaman, tanaman *tomato* dan *potato* masing-masing memiliki 3.652 rekaman, jauh lebih banyak dibandingkan enam tanaman lainnya yang masing-masing hanya memiliki 100 rekaman. Jika model dilatih langsung pada data yang tidak seimbang ini, model akan cenderung bias ke arah kelas mayoritas dan mengabaikan kelas minoritas, menghasilkan akurasi keseluruhan yang tinggi tetapi performa yang buruk pada kelas minoritas.

Untuk mengatasi ketidakseimbangan ini, diterapkan metode *random undersampling* di mana setiap kelas di-*sampling* secara acak sebanyak 100 rekaman menggunakan fungsi `groupby().apply(lambda x: x.sample(100))` dalam *pandas*. Metode ini dipilih karena kesederhanaannya dan karena 100 rekaman per kelas dianggap masih cukup representatif untuk melatih model *Random Forest* yang memiliki kemampuan generalisasi yang baik. Setelah proses *balancing*, dataset latih berisi 800 rekaman yang terdistribusi secara merata, yaitu 100 rekaman untuk masing-masing dari delapan kelas tanaman. Kemudian, dataset seimbang ini dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan fungsi `train_test_split` dengan parameter *stratify* yang memastikan proporsi kelas tetap terjaga di kedua subset.

Tahap *preprocessing* selanjutnya adalah label *encoding* dan *feature scaling*. Label *encoding* dilakukan menggunakan *LabelEncoder* dari *scikit-learn* untuk mengkonversi nama tanaman berupa string menjadi representasi numerik integer yang dapat diproses oleh algoritma *Machine Learning*. Hasil *encoding* menghasilkan pemetaan sebagai berikut: *banana* bernilai 0, *maize* bernilai 1, *mungbean* bernilai 2, *orange* bernilai 3, *papaya* bernilai 4, *potato* bernilai 5, *tomato* bernilai 6, dan *watermelon* bernilai 7. *Feature scaling* kemudian dilakukan menggunakan *StandardScaler* yang mentransformasi setiap fitur numerik sehingga memiliki rata-rata nol dan deviasi standar satu. Meskipun *Random Forest* secara teknis tidak memerlukan *feature scaling* karena berbasis pohon keputusan yang tidak sensitif terhadap skala, *scaling* tetap dilakukan untuk memastikan kompatibilitas dengan sistem inferensi yang menggunakan data cuaca *real-time* dari BMKG yang mungkin memiliki distribusi berbeda.

2.5.2. Pelatihan dan Evaluasi Model

Model *Random Forest Classifier* dibangun dengan konfigurasi *n_estimators*

sebesar 100, yang berarti model terdiri dari 100 pohon keputusan independen yang dilatih secara bersamaan pada subset data yang berbeda. Nilai 100 dipilih sebagai titik keseimbangan antara akurasi dan efisiensi komputasi, berdasarkan temuan bahwa penambahan estimator di atas 100 umumnya tidak memberikan peningkatan akurasi yang signifikan untuk dataset berukuran sedang (Oshiro et al., 2012). Parameter *random_state* ditetapkan pada nilai 42 untuk memastikan reproduktibilitas eksperimen, sehingga hasil pelatihan yang sama akan diperoleh setiap kali model dilatih ulang dengan data yang sama. Setelah proses pelatihan selesai, model dievaluasi pada data uji menggunakan tiga metrik evaluasi utama, yaitu *accuracy*, *classification report* (yang mencakup *precision*, *recall*, dan *F1-score* per kelas), dan *confusion matrix*.

Hasil evaluasi model menunjukkan akurasi keseluruhan sebesar 80,625 persen pada data uji yang terdiri dari 160 sampel. Analisis *classification report* memberikan gambaran yang lebih detail mengenai performa model pada masing-masing kelas. Kelas *maize* (kode 1) mencapai *precision*, *recall*, dan *F1-score* sempurna sebesar 1,00, menunjukkan bahwa model mampu mengidentifikasi jagung tanpa kesalahan apapun. Kelas *mungbean* (kode 2) juga menunjukkan performa yang sangat baik dengan *F1-score* sebesar 0,97. Di sisi lain, kelas *potato* (kode 5) dan *tomato* (kode 6) menunjukkan *F1-score* terendah masing-masing sebesar 0,50, yang mengindikasikan bahwa kedua tanaman ini memiliki karakteristik cuaca dan tanah yang sangat mirip sehingga sulit dibedakan oleh model. Temuan ini konsisten dengan kenyataan bahwa kentang dan tomat memang merupakan tanaman dari keluarga *Solanaceae* yang memiliki kebutuhan iklim yang serupa.

Tabel 2.2. Hasil Evaluasi Model Random Forest pada Data Uji

No	Kelas Tanaman	Precicion	Recall	<i>F1-score</i>	Support
1.	<i>Banana</i> (0)	0.92	0.92	0.92	24
2.	<i>Maize</i> (1)	1.00	1.00	1.00	13
3.	<i>Mungbean</i> (2)	1.00	0.95	0.97	20
4.	<i>Orange</i> (3)	0.95	0.83	0.88	23
5.	<i>Papaya</i> (4)	0.76	1.00	0.87	13
6.	<i>Potato</i> (5)	0.50	0.50	0.50	22
7.	<i>Tomato</i> (6)	0.50	0.50	0.50	22
8.	<i>Watermelon</i> (7)	0.91	0.91	0.91	23

9.	Rata-rata	0.81	0.81	0.81	160
	Keseluruhan				

Model yang telah dievaluasi kemudian disimpan dalam tiga *file* serialisasi terpisah menggunakan pustaka *joblib* dari *Python*. Pemisahan penyimpanan antara model, label *encoder*, dan *scaler* dilakukan secara sengaja untuk memudahkan pembaruan komponen individual tanpa harus melatih ulang seluruh *pipeline*. Sebagai contoh, jika di masa mendatang terdapat dataset tanaman baru yang ingin ditambahkan, label *encoder* dapat diperbarui secara terpisah tanpa harus mengubah model inti. Pendekatan modular dalam penyimpanan model ini sejalan dengan praktik terbaik dalam *Machine Learning Engineering* yang menekankan pemisahan antara komponen-komponen *pipeline* yang memiliki siklus hidup berbeda (Huyen, 2022).

2.6. Perancangan Antarmuka Website

Antarmuka website dirancang dengan mengutamakan prinsip kemudahan penggunaan (*usability*) dan aksesibilitas informasi bagi pengguna dengan berbagai tingkat literasi teknologi. Desain antarmuka mengikuti pendekatan *user-centered design* yang menekankan bahwa tampilan dan alur interaksi sistem harus disesuaikan dengan kebutuhan dan kemampuan pengguna sasaran, bukan dengan preferensi atau konvensi teknis pengembang (Norman, 2013). Halaman utama website menyediakan formulir *input* yang sederhana dan intuitif di mana pengguna dapat memilih provinsi atau kabupaten dari daftar *dropdown* yang telah tersedia, serta memilih jenis tanaman yang ingin ditanam dari daftar delapan tanaman yang ditangani sistem.

Setelah pengguna mengirimkan *input*, sistem secara otomatis mengeksekusi serangkaian proses di lapisan *backend*, yaitu: pertama, melakukan panggilan ke API BMKG untuk mendapatkan data cuaca terkini di lokasi yang dipilih; kedua, mengekstrak nilai suhu dan kelembapan dari respons API tersebut; ketiga, meminta pengguna untuk memasukkan atau mengkonfirmasi nilai *ph* tanah di lokasi mereka; keempat, menggabungkan ketiga nilai tersebut dan menormalkannya menggunakan *scaler* yang tersimpan; kelima, meneruskan vektor fitur yang telah dinormalisasi ke model *Random Forest* untuk mendapatkan prediksi kelas tanaman; dan keenam, menampilkan hasil prediksi beserta tingkat kepercayaan dan visualisasi data kepada pengguna. Seluruh

proses ini terjadi dalam hitungan detik, memberikan pengalaman pengguna yang responsif dan interaktif.

Dashboard visualisasi data merupakan komponen antarmuka yang berfungsi untuk menyajikan informasi perkebunan dan cuaca dalam format grafis yang mudah dipahami. Visualisasi yang ditampilkan mencakup grafik distribusi suhu dan kelembapan historis untuk tanaman yang dipilih, grafik perbandingan kondisi cuaca aktual dengan rentang ideal untuk masing-masing tanaman, serta indikator risiko berbasis warna yang memberikan gambaran cepat mengenai tingkat kesesuaian kondisi saat ini dengan kebutuhan tanaman. Pendekatan visualisasi data ini didasarkan pada prinsip-prinsip yang dikemukakan oleh Few (2012) dalam bukunya *Show Me the Numbers*, yang menekankan bahwa visualisasi data yang efektif harus mampu menyampaikan informasi yang relevan dengan cepat dan jelas tanpa memerlukan interpretasi yang rumit dari pengguna.

BAB III

METOLOGI PENELITIAN

3.1. Gambaran Umum Sistem yang Dikembangkan

Sistem yang dikembangkan dalam penelitian ini merupakan sebuah platform *Business Intelligence* berbasis web yang mengintegrasikan tiga komponen utama secara sinergis, yaitu *Data Warehouse* berbasis *star schema*, model *Machine Learning Random Forest Classifier*, dan data cuaca *real-time* yang bersumber dari API Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) Republik Indonesia. Secara fungsional, sistem ini berperan sebagai *Decision support system* (DSS) di bidang perkebunan yang membantu pengguna dalam menentukan jenis tanaman yang paling sesuai untuk ditanam di suatu wilayah berdasarkan kondisi cuaca aktual di lokasi tersebut. Pendekatan ini merepresentasikan implementasi nyata dari konsep *Business Intelligence* generasi terkini yang tidak hanya mengandalkan data historis, tetapi juga mampu merespons perubahan kondisi lingkungan secara dinamis dan *real-time* (Kimball & Ross, 2013).

Sistem ini dirancang untuk melayani dua kelompok pengguna utama. Kelompok pertama adalah petani dan penyuluh perkebunan yang membutuhkan informasi praktis dan cepat mengenai kelayakan penanaman suatu komoditas di lokasi mereka pada waktu tertentu. Kelompok kedua adalah pemangku kepentingan sektor perkebunan seperti dinas perkebunan daerah, koperasi, dan peneliti yang membutuhkan akses terhadap visualisasi data perkebunan secara agregat untuk keperluan perencanaan dan analisis kebijakan. Dengan menyasar dua kelompok pengguna yang berbeda ini, sistem menerapkan desain antarmuka berlapis di mana informasi yang paling penting disajikan secara ringkas di halaman utama, sementara detail analitik yang lebih mendalam tersedia melalui *dashboard* visualisasi yang dapat diakses pengguna yang lebih teknis. Desain berlapis semacam ini dikenal dalam literatur *Human-Computer Interaction* sebagai *progressive disclosure*, yaitu strategi penyajian informasi yang menyembunyikan kompleksitas sistem dari pengguna kasual sambil tetap menyediakan akses ke fitur yang lebih canggih bagi pengguna yang membutuhkannya (Tidwell, 2010).

Secara teknis, sistem dibangun menggunakan *stack* teknologi berbasis *Python* untuk lapisan *backend*, yang mencakup *framework* web *Flask* untuk pengelolaan *routing* dan pemrosesan permintaan HTTP, pustaka *scikit-learn* untuk memuat dan mengeksekusi

model *Machine Learning*, pustaka *pandas* untuk manipulasi data, dan pustaka *requests* untuk melakukan panggilan ke API BMKG. Lapisan *frontend* dibangun menggunakan HTML, CSS, dan JavaScript dengan bantuan pustaka visualisasi *Chart.js* untuk menampilkan grafik interaktif pada *dashboard*. Seluruh komponen model *Machine Learning* disimpan dalam format serialisasi.pkl menggunakan *joblib* dan dimuat ke dalam memori server saat aplikasi pertama kali dijalankan, sehingga proses inferensi dapat dilakukan secara cepat tanpa *overhead* pembacaan *file* pada setiap permintaan pengguna.

3.2. Hasil Implementasi *Data Warehouse*

3.2.1. Struktur dan Isi Tabel Dimensi

Implementasi *Data Warehouse* menghasilkan empat tabel yang membentuk skema bintang (*star schema*) sesuai dengan rancangan yang telah ditetapkan pada tahap perancangan. Tabel pertama yang berhasil diimplementasikan adalah tabel *dim_crop* yang berfungsi sebagai dimensi tanaman. Tabel ini memuat delapan rekaman yang merepresentasikan seluruh jenis tanaman yang ditangani oleh sistem, yaitu *maize* (jagung) dengan *crop_id* bernilai 1, *mungbean* (kacang hijau) dengan *crop_id* bernilai 2, *banana* (pisang) dengan *crop_id* bernilai 3, *watermelon* (semangka) dengan *crop_id* bernilai 4, *orange* (jeruk) dengan *crop_id* bernilai 5, *papaya* (pepaya) dengan *crop_id* bernilai 6, *tomato* (tomat) dengan *crop_id* bernilai 7, dan *potato* (kentang) dengan *crop_id* bernilai 8. Meskipun sederhana dalam strukturnya, tabel ini memainkan peran penting sebagai referensi master data tanaman yang menjamin konsistensi penamaan dan identifikasi tanaman di seluruh komponen sistem.

Tabel kedua yang berhasil diimplementasikan adalah tabel *dim_weather* yang berfungsi sebagai dimensi cuaca. Tabel ini memuat 7.904 rekaman kondisi cuaca yang merepresentasikan seluruh kombinasi suhu dan kelembapan yang terdapat dalam dataset bersih. Setiap rekaman dalam tabel ini memiliki *weather_id* sebagai kunci primer, nilai *temperature* dalam derajat Celsius, dan nilai *humidity* dalam persen. Analisis statistik terhadap tabel ini menunjukkan bahwa nilai suhu terdistribusi dalam rentang negatif 0,65 hingga 51,68 derajat Celsius dengan nilai rata-rata 24,14 derajat Celsius dan deviasi standar 8,70 derajat Celsius. Nilai kelembapan terdistribusi dalam rentang 48,32 hingga 94,96 persen dengan nilai rata-rata 74,91 persen dan deviasi standar 7,46 persen. Rentang nilai yang cukup luas ini mencerminkan keragaman kondisi iklim yang mencakup

berbagai zona agroklimat, dari daerah bersuhu dingin seperti dataran tinggi hingga daerah tropis panas yang umum dijumpai di Indonesia.

Tabel ketiga adalah tabel *dim_soil* yang berfungsi sebagai dimensi tanah dengan fokus pada parameter keasaman tanah (*ph*). Tabel ini memuat 605 rekaman nilai *ph* unik yang terdistribusi dalam rentang 5,50 hingga 8,00 dengan nilai rata-rata 6,54 dan deviasi standar 0,50. Rentang *ph* ini sepenuhnya berada dalam zona yang relevan untuk perkebunan, mengingat sebagian besar tanaman pangan tumbuh optimal pada *ph* antara 5,5 hingga 7,5 (Brady & Weil, 2016). Jumlah rekaman *dim_soil* yang lebih kecil dibandingkan *dim_weather* mencerminkan fakta bahwa variasi kondisi tanah dalam dataset yang digunakan tidak sebesar variasi kondisi cuaca, yang secara logis dapat dijelaskan oleh kenyataan bahwa *ph* tanah merupakan parameter yang relatif stabil dan berubah dalam rentang yang lebih sempit dibandingkan suhu dan kelembapan udara yang dapat berfluktuasi signifikan dari waktu ke waktu.

3.2.2. Struktur dan Isi Tabel Fakta

Tabel fakta bernama *fact_prediction* merupakan komponen sentral dari *Data Warehouse* yang berhasil diimplementasikan dengan total 7.904 rekaman tanpa nilai yang hilang (*null values*). Setiap rekaman dalam tabel fakta ini merepresentasikan satu observasi data perkebunan yang mengintegrasikan informasi dari ketiga dimensi secara bersamaan melalui kunci asing. Kolom *prediction_id* berfungsi sebagai kunci primer dengan nilai yang berurutan dari 1 hingga 7.904. Kolom *crop_id* merujuk ke tabel *dim_crop* dan memiliki distribusi yang mencerminkan ketidakseimbangan kelas dalam dataset mentah, di mana tanaman *tomato* dan *potato* mendominasi dengan masing-masing 3.652 rekaman, sementara enam tanaman lainnya masing-masing memiliki 100 rekaman. Kolom *weather_id* merujuk ke tabel *dim_weather* dengan nilai yang unik untuk setiap rekaman, sedangkan kolom *soil_id* merujuk ke tabel *dim_soil* dengan nilai yang berulang karena jumlah kondisi tanah unik lebih sedikit dibandingkan total rekaman.

Integritas referensial dalam *Data Warehouse* ini dijaga dengan memastikan bahwa setiap nilai kunci asing dalam tabel fakta memiliki padanan yang valid dalam tabel dimensi yang dirujuknya. Verifikasi terhadap integritas ini dilakukan melalui proses validasi silang (*cross-validation*) antara tabel fakta dan masing-masing tabel dimensi selama fase implementasi ETL. Hasil verifikasi menunjukkan bahwa tidak terdapat rekaman yatim (*orphaned records*) dalam tabel fakta, yaitu rekaman yang memiliki nilai

kunci asing yang tidak ditemukan dalam tabel dimensi yang sesuai. Keberhasilan implementasi *Data Warehouse* ini memenuhi empat kriteria fundamental yang ditetapkan oleh Inmon (1992), yaitu berorientasi subjek karena berfokus pada domain rekomendasi tanaman, terintegrasi karena menggabungkan dua sumber dataset yang berbeda, tidak berubah karena data historis tidak dimodifikasi setelah dimuat, dan bervariasi terhadap waktu karena data cuaca *real-time* yang diperoleh dari BMKG terus diperbarui sesuai dengan waktu permintaan.

3.2.3. Validasi Proses ETL

Proses ETL yang dilaksanakan menghasilkan dataset bersih dengan tingkat kualitas data yang tinggi, sebagaimana dibuktikan oleh beberapa indikator kualitas yang diukur pasca-transformasi. Pertama, tingkat kelengkapan data (*completeness*) mencapai 100 persen, yang berarti tidak terdapat satu pun nilai yang hilang pada kolom-kolom yang digunakan dalam dataset bersih *crop_dataset.csv*. Kedua, tingkat konsistensi data (*consistency*) juga mencapai 100 persen, yang berarti seluruh nilai pada kolom *crop_name* menggunakan format penulisan yang seragam dalam huruf kecil (*lowercase*) dan tidak terdapat variasi penulisan nama yang merujuk pada entitas tanaman yang sama. Ketiga, tingkat validitas data (*validity*) diverifikasi dengan memastikan bahwa seluruh nilai numerik berada dalam rentang yang logis secara agronomi, yaitu suhu tidak melebihi 55 derajat Celsius, kelembapan berada antara 0 dan 100 persen, dan *ph* berada antara 0 dan 14.

Selama proses *Transformasi*, ditemukan satu permasalahan kualitas data yang perlu ditangani, yaitu adanya nilai suhu negatif sebesar negatif 0,65 derajat Celsius pada beberapa rekaman dalam dataset bersih. Nilai ini secara teknis valid karena berada dalam rentang yang dapat diukur oleh termometer standar, namun secara agronomi tidak relevan untuk kondisi perkebunan tropis. Keputusan yang diambil adalah mempertahankan nilai-nilai tersebut dalam dataset tanpa modifikasi, mengingat nilai tersebut mungkin merepresentasikan kondisi iklim di daerah dataran tinggi yang juga relevan untuk beberapa jenis tanaman yang ditangani sistem. Keputusan ini sejalan dengan prinsip yang dikemukakan oleh Kimball dan Ross (2013) bahwa data dalam *Data Warehouse* tidak boleh dimodifikasi secara sewenang-wenang kecuali terdapat alasan yang sangat kuat berdasarkan pengetahuan domain (*domain knowledge*).

3.3. Hasil Implementasi Model *Machine Learning*

3.3.1. Performa Model pada Data Latih dan Data Uji

Model *Random Forest Classifier* yang dilatih pada dataset seimbang dengan 800 rekaman (100 rekaman per kelas) dan diuji pada 160 rekaman data uji menunjukkan performa yang memuaskan dengan akurasi keseluruhan sebesar 80,625 persen. Nilai akurasi ini mengindikasikan bahwa dari 160 sampel data uji, model berhasil mengklasifikasikan 129 sampel dengan benar dan salah mengklasifikasikan 31 sampel. Untuk memberikan konteks yang lebih bermakna terhadap angka akurasi ini, perlu dipahami bahwa nilai akurasi sebesar 80,625 persen pada masalah klasifikasi delapan kelas jauh lebih baik dibandingkan dengan *baseline random classifier* yang hanya akan mencapai akurasi sekitar 12,5 persen (1 dibagi 8). Dengan demikian, model yang dibangun menunjukkan kemampuan diskriminasi yang jauh melampaui prediksi acak, membuktikan bahwa terdapat pola yang dapat dipelajari oleh model dari kombinasi fitur suhu, kelembapan, dan *ph* tanah.

Analisis yang lebih mendalam terhadap *classification report* mengungkap adanya variasi performa yang signifikan antar kelas tanaman. Tiga kelas menunjukkan performa yang sangat baik dengan *F1-score* di atas 0,90, yaitu *maize* dengan *F1-score* sempurna 1,00, *mungbean* dengan *F1-score* 0,97, dan *banana* dengan *F1-score* 0,92. Tiga kelas lainnya menunjukkan performa baik dengan *F1-score* antara 0,85 dan 0,92, yaitu *watermelon* dengan 0,91, *orange* dengan 0,88, dan *papaya* dengan 0,87. Dua kelas terakhir, yaitu *potato* dan *tomato*, menunjukkan performa terendah dengan *F1-score* sebesar 0,50 untuk keduanya. Pola ini sangat konsisten dengan pemahaman botanis bahwa kentang dan tomat merupakan tanaman dari famili yang sama (*Solanaceae*) yang memiliki kebutuhan iklim dan kondisi tanah yang sangat mirip, sehingga secara matematis sulit untuk dibedakan hanya berdasarkan tiga fitur yang digunakan (suhu, kelembapan, dan *ph*) tanpa informasi tambahan seperti kandungan nutrisi tanah atau ketinggian wilayah.

Temuan mengenai rendahnya performa model pada kelas *potato* dan *tomato* ini memiliki implikasi praktis yang penting bagi pengguna sistem. Ketika sistem memberikan rekomendasi untuk salah satu dari dua tanaman tersebut, tingkat kepercayaan rekomendasi secara *inherent* lebih rendah dibandingkan rekomendasi untuk tanaman lainnya. Untuk mengkomunikasikan hal ini kepada pengguna secara transparan,

sistem dirancang untuk menampilkan probabilitas prediksi untuk setiap kelas tanaman bersamaan dengan rekomendasi utama. Metode *predict_proba()* dari scikit-learn digunakan untuk mengekstrak probabilitas prediksi dari model *Random Forest*, yang merepresentasikan proporsi pohon dalam *ensemble* yang memberikan suara untuk masing-masing kelas. Dengan menampilkan probabilitas ini, pengguna dapat menilai sendiri tingkat keyakinan sistem terhadap rekomendasinya dan mempertimbangkan alternatif tanaman yang mungkin sama-sama layak.

3.3.2. Analisis Fitur Penting (Feature Importance)

Salah satu keunggulan algoritmik dari *Random Forest* adalah kemampuannya untuk menghasilkan metrik kepentingan fitur (*feature importance*) yang memberikan wawasan mengenai kontribusi relatif masing-masing variabel *input* terhadap akurasi prediksi model. Analisis *feature importance* terhadap model yang dilatih menunjukkan bahwa ketiga fitur memiliki kontribusi yang berbeda-beda namun seluruhnya berkontribusi secara bermakna. Fitur suhu (*temperature*) merupakan prediktor terpenting dengan skor kepentingan tertinggi, yang secara logis masuk akal mengingat toleransi suhu merupakan salah satu faktor pembatas utama dalam distribusi tanaman secara global. Fitur kelembapan (*humidity*) merupakan prediktor kedua terpentingnya, mencerminkan peran kelembapan udara dalam mengatur laju transpirasi dan kebutuhan air tanaman. Fitur *ph* tanah berada di posisi ketiga, dengan kontribusi yang lebih kecil namun tetap signifikan dalam membedakan tanaman-tanaman yang memiliki preferensi keasaman tanah yang berbeda.

Temuan mengenai urutan kepentingan fitur ini konsisten dengan literatur agronomi yang menyatakan bahwa suhu merupakan faktor iklim paling determinan dalam menentukan distribusi geografis dan musiman tanaman (Hatfield & Prueger, 2015). Setiap tanaman memiliki rentang suhu kardinal yang terdiri dari suhu minimum, suhu optimum, dan suhu maksimum yang menentukan batas-batas pertumbuhannya. Sebagai contoh, jagung (*maize*) tumbuh optimal pada suhu antara 21 hingga 30 derajat Celsius, sementara kentang (*potato*) justru lebih menyukai suhu yang lebih dingin antara 15 hingga 20 derajat Celsius. Perbedaan preferensi suhu yang cukup jelas antar spesies inilah yang menjadikan suhu sebagai fitur paling informatif bagi model dalam membedakan kelas-kelas tanaman. Pemahaman ini juga menjelaskan mengapa model justru kesulitan membedakan kentang dan tomat, karena kedua tanaman memiliki rentang suhu optimal

yang sangat tumpang tindih, yaitu sekitar 18 hingga 26 derajat Celsius untuk keduanya.

3.3.3. Penyimpanan dan Pemuatan Model

Model yang telah dilatih dan dievaluasi disimpan dalam tiga *file* terpisah menggunakan pustaka *joblib*, yang merupakan pustaka *Python* yang dioptimalkan untuk serialisasi objek berukuran besar yang mengandung *array NumPy* seperti model *scikit-learn*. *File* pertama adalah *crop_model.pkl* dengan ukuran sekitar 2,86 MB yang menyimpan seluruh objek *RandomForestClassifier* beserta 100 pohon keputusan yang membentuknya. *File* kedua adalah *label_encoder.pkl* dengan ukuran 550 *byte* yang menyimpan objek *LabelEncoder* beserta pemetaan antara label string tanaman dan representasi integer yang digunakan selama pelatihan. *File* ketiga adalah *scaler.pkl* dengan ukuran 959 *byte* yang menyimpan objek *StandardScaler* beserta parameter mean dan deviasi standar yang dihitung dari data latih, yang diperlukan untuk menormalkan data *input* baru dengan cara yang identik dengan normalisasi yang dilakukan selama pelatihan.

Saat aplikasi web dijalankan, ketiga *file* tersebut dimuat ke dalam memori server menggunakan fungsi *joblib.Load()* dan disimpan sebagai variabel global yang dapat diakses oleh seluruh fungsi penanganan permintaan. Pendekatan pemuatan model satu kali di awal (*one-time Loading*) ini dipilih untuk meminimalkan latensi inferensi, karena proses deserialisasi *file* model berukuran hampir 3 MB membutuhkan waktu yang tidak dapat diabaikan jika dilakukan pada setiap permintaan pengguna. Dalam pengujian yang dilakukan, waktu inferensi rata-rata setelah model dimuat ke memori adalah di bawah 10 milidetik per permintaan, yang merupakan latensi yang sangat dapat diterima untuk aplikasi web interaktif. Performa inferensi ini konsisten dengan karakteristik umum *Random Forest* yang memiliki kompleksitas waktu inferensi sebesar $O(k \log n)$ di mana k adalah jumlah pohon dan n adalah jumlah rekaman pelatihan, menghasilkan prediksi yang sangat cepat meskipun model terdiri dari 100 pohon keputusan (Louppe, 2014).

3.4. Hasil Integrasi API BMKG

3.4.1. Mekanisme Pengambilan Data Cuaca

Integrasi dengan API BMKG merupakan komponen yang menjadikan sistem ini bersifat dinamis dan responsif terhadap kondisi lingkungan aktual. API BMKG menyediakan data prakiraan cuaca dalam format JSON yang terstruktur dan dapat diakses

melalui *endpoint* publik berdasarkan kode wilayah administratif Indonesia. Ketika pengguna memilih suatu lokasi pada antarmuka website, sistem *backend* melakukan permintaan HTTP GET ke *endpoint* API BMKG yang sesuai dan mengurai respons JSON yang diterima untuk mengekstrak nilai suhu dan kelembapan yang relevan. Proses penguraian (*parsing*) respons API ini dilakukan dengan hati-hati mengingat struktur respons API BMKG dapat bervariasi tergantung pada jenis data cuaca yang diminta dan versi API yang digunakan.

Data cuaca yang diekstrak dari API BMKG kemudian melalui serangkaian proses validasi sebelum digunakan sebagai *input* model. Validasi pertama adalah pemeriksaan tipe data untuk memastikan bahwa nilai suhu dan kelembapan yang diekstrak berupa angka (numerik) dan bukan *string* atau nilai *null*. Validasi kedua adalah pemeriksaan rentang nilai untuk memastikan bahwa nilai suhu berada dalam rentang yang logis secara fisik, yaitu antara negatif 20 hingga 60 derajat Celsius, dan nilai kelembapan berada antara 0 dan 100 persen. Jika salah satu validasi gagal, sistem akan menampilkan pesan kesalahan yang informatif kepada pengguna dan meminta mereka untuk memasukkan nilai secara manual sebagai alternatif. Mekanisme *fallback* ke *input* manual ini penting untuk memastikan bahwa kegagalan layanan API eksternal tidak menyebabkan sistem secara keseluruhan tidak dapat digunakan, menerapkan prinsip *graceful degradation* dalam desain sistem yang *robust* (Nygard, 2007).

3.4.2. Proses Inferensi *Real-time*

Setelah data cuaca berhasil diperoleh dari API BMKG dan nilai *ph* tanah dimasukkan atau dikonfirmasi oleh pengguna, sistem melakukan proses inferensi *real-time* yang mengikuti *pipeline* yang identik dengan *pipeline* yang digunakan selama pelatihan model. Langkah pertama adalah pembentukan vektor fitur sebagai *array NumPy* berisi tiga nilai, yaitu *temperature*, *humidity*, dan *ph*, yang diambil dari data BMKG dan *input* pengguna. Langkah kedua adalah normalisasi vektor fitur menggunakan objek *StandardScaler* yang telah dimuat dari *file scaler.pkl*, dengan memanggil metode *Transform()* yang menerapkan *Transformasi* linear berdasarkan parameter mean dan deviasi standar yang dihitung dari data latih. Penting untuk dipahami bahwa pada tahap inferensi ini digunakan metode *Transform()* dan bukan *fit_Transform()*, karena parameter *scaling* harus tetap konsisten dengan yang digunakan selama pelatihan untuk memastikan keabsahan prediksi.

Langkah ketiga adalah eksekusi prediksi menggunakan model *Random Forest* dengan memanggil metode *predict()* untuk mendapatkan kelas yang diprediksi dan metode *predict_proba()* untuk mendapatkan vektor probabilitas prediksi untuk seluruh delapan kelas. *Output* dari *predict()* berupa integer yang kemudian diterjemahkan kembali ke nama tanaman menggunakan objek *LabelEncoder* melalui metode *inverse_Transform()*. *Output* dari *predict_proba()* berupa *array* delapan nilai probabilitas yang masing-masing merepresentasikan keyakinan model terhadap masing-masing kelas tanaman, di mana jumlah seluruh nilai probabilitas selalu sama dengan 1,00. Pasangan nilai prediksi kelas dan vektor probabilitas ini kemudian digunakan oleh lapisan presentasi untuk menampilkan rekomendasi utama, tingkat kepercayaan rekomendasi, serta tiga tanaman alternatif dengan probabilitas tertinggi berikutnya.

3.5. Hasil dan Pembahasan Antarmuka Website

3.5.1. Halaman Utama dan Form Input

Halaman utama website menyajikan antarmuka yang bersih dan terfokus dengan elemen-elemen yang disusun secara hierarkis mengikuti prinsip visual *hierarchy* dalam desain antarmuka pengguna. Bagian paling atas halaman menampilkan judul dan deskripsi singkat sistem yang menginformasikan kepada pengguna mengenai tujuan dan kemampuan sistem. Di bawahnya terdapat *form input* utama yang terdiri dari dua elemen interaksi, yaitu *dropdown* pemilihan lokasi yang memuat daftar kabupaten dan kota di seluruh Indonesia, serta *dropdown* pemilihan tanaman yang memuat delapan pilihan komoditas yang dapat dianalisis. Setelah pengguna memilih lokasi dan tanaman kemudian menekan tombol analisis, sistem secara otomatis menampilkan kolom *input* tambahan untuk nilai *ph* tanah yang dilengkapi dengan panduan nilai *ph* yang umum untuk masing-masing jenis tanah di Indonesia, membantu pengguna yang mungkin tidak memiliki data *ph* yang tepat untuk memberikan estimasi yang mendekati kondisi aktual lahannya.

Pengujian *usability* terhadap halaman utama menunjukkan bahwa alur interaksi yang dirancang cukup intuitif bagi pengguna dengan berbagai tingkat keakraban terhadap teknologi. Pengguna dapat menyelesaikan seluruh proses dari pemilihan lokasi hingga mendapatkan rekomendasi dalam waktu kurang dari satu menit. Responsivitas antarmuka terhadap berbagai ukuran layar, mulai dari *smartphone* hingga monitor desktop, berhasil

diimplementasikan melalui penggunaan CSS *Flexbox* dan media *query* yang memastikan tampilan yang optimal di seluruh perangkat. Hal ini penting mengingat sebagian besar petani saat ini mengakses internet melalui perangkat *smartphone*, sehingga antarmuka yang responsif terhadap layar kecil merupakan prasyarat aksesibilitas yang tidak dapat diabaikan (APJII, 2023).

3.5.2. Halaman Hasil Rekomendasi

Halaman hasil rekomendasi merupakan komponen antarmuka yang paling kaya informasi dalam sistem ini. Informasi disajikan dalam tata letak yang terstruktur dengan tiga bagian utama. Bagian pertama menampilkan panel rekomendasi utama yang mencakup nama tanaman yang direkomendasikan, ikon visual tanaman, tingkat kepercayaan rekomendasi dalam bentuk persentase yang diturunkan dari nilai probabilitas tertinggi yang diberikan oleh model, serta label status kecocokan yang menggunakan kode warna hijau untuk sangat cocok, kuning untuk cocok dengan catatan, dan merah untuk tidak cocok. Penentuan kategori status ini didasarkan pada ambang batas probabilitas yang ditetapkan, yaitu probabilitas di atas 0,70 dikategorikan sebagai sangat cocok, antara 0,40 hingga 0,70 dikategorikan sebagai cocok dengan catatan, dan di bawah 0,40 dikategorikan sebagai tidak cocok atau berisiko tinggi.

Bagian kedua dari halaman hasil menampilkan panel informasi cuaca yang memuat data aktual dari BMKG, yaitu suhu saat ini, kelembapan relatif, dan kondisi cuaca umum di lokasi yang dipilih, serta perbandingan visualnya dengan rentang ideal untuk tanaman yang diinputkan pengguna. Perbandingan ini disajikan menggunakan grafik *gauge* berbentuk setengah lingkaran yang secara visual menunjukkan posisi nilai aktual dalam kontinum antara kondisi tidak ideal dan kondisi optimal untuk tanaman tersebut. Grafik ini diimplementasikan menggunakan pustaka *Chart.js* yang memungkinkan rendering grafik interaktif langsung di browser tanpa memerlukan pemrosesan sisi server yang tambahan. Bagian ketiga menampilkan tabel alternatif tanaman yang memuat empat tanaman alternatif dengan probabilitas tertinggi setelah tanaman yang dipilih pengguna, disertai dengan nilai probabilitas masing-masing dan ringkasan kondisi idealnya. Penyajian alternatif tanaman ini memberikan nilai tambah yang signifikan bagi pengguna, karena membantu mereka untuk tidak hanya mengetahui apakah tanaman pilihannya cocok, tetapi juga tanaman lain apa yang lebih berpotensi berhasil di lokasi dan kondisi cuaca mereka saat ini.

3.5.3. *Dashboard* Visualisasi Data

Dashboard visualisasi data merupakan fitur lanjutan yang ditujukan terutama bagi pengguna yang membutuhkan pemahaman yang lebih mendalam mengenai pola data perkebunan yang mendasari rekomendasi sistem. *Dashboard* ini menampilkan empat jenis visualisasi yang saling melengkapi. Visualisasi pertama adalah grafik *scatter plot* yang memplot distribusi nilai suhu dan kelembapan dari seluruh rekaman dalam *Data Warehouse*, dengan titik-titik data diberi warna berbeda sesuai dengan kelas tanamannya. Grafik ini memberikan gambaran visual yang intuitif mengenai bagaimana masing-masing tanaman menempati zona yang berbeda dalam ruang fitur dua dimensi suhu-kelembapan, dan juga menunjukkan di mana posisi kondisi cuaca aktual pengguna berada relatif terhadap distribusi data historis.

Visualisasi kedua adalah grafik *box plot* yang menampilkan distribusi statistik nilai suhu dan kelembapan untuk masing-masing jenis tanaman secara terpisah, menunjukkan nilai minimum, kuartil pertama, median, kuartil ketiga, dan maksimum untuk setiap kelas. *Box plot* ini memberikan pemahaman yang lebih detail mengenai rentang dan variabilitas kondisi cuaca yang terkait dengan masing-masing tanaman dalam dataset historis. Visualisasi ketiga adalah grafik *bar chart* yang menampilkan nilai probabilitas prediksi untuk seluruh delapan kelas tanaman berdasarkan kondisi *input* pengguna saat ini, memberikan gambaran menyeluruh mengenai distribusi keyakinan model terhadap seluruh kemungkinan prediksi. Visualisasi keempat adalah *heatmap* korelasi yang menampilkan tingkat korelasi antar variabel numerik dalam dataset, yaitu *temperature*, *humidity*, dan *ph*, membantu pengguna yang lebih teknis dalam memahami hubungan statistik antar variabel yang digunakan oleh model.

3.6. Pengujian Sistem

3.6.1. Pengujian Fungsional

Pengujian fungsional dilakukan untuk memverifikasi bahwa seluruh fitur dan alur interaksi sistem berjalan sesuai dengan spesifikasi yang telah ditetapkan. Pengujian menggunakan metode Black-Box Testing, di mana sistem diperlakukan sebagai kotak hitam yang hanya diobservasi dari sudut pandang *input* dan *output* tanpa memperhatikan implementasi internal. Pengujian fungsional mencakup lima skenario utama yang masing-masing dirancang untuk memverifikasi satu aspek fungsionalitas sistem.

Skenario pertama adalah pengujian integrasi API BMKG dengan memberikan berbagai kode lokasi yang valid dan memverifikasi bahwa data cuaca yang dikembalikan sesuai dengan kondisi cuaca aktual yang dapat diverifikasi secara independen. Skenario kedua adalah pengujian inferensi model dengan memberikan kombinasi nilai suhu, kelembapan, dan *ph* yang diketahui karakteristiknya secara agronomi dan memverifikasi bahwa rekomendasi yang dihasilkan konsisten dengan pengetahuan ilmiah mengenai kebutuhan tumbuh masing-masing tanaman.

Skenario ketiga adalah pengujian penanganan kesalahan dengan mensimulasikan kondisi di mana API BMKG tidak dapat diakses dan memverifikasi bahwa sistem memberikan pesan kesalahan yang informatif serta menyediakan alternatif *input* manual. Skenario keempat adalah pengujian antarmuka responsif dengan mengakses sistem dari berbagai perangkat dan resolusi layar yang berbeda dan memverifikasi konsistensi tampilan serta fungsionalitas di seluruh kondisi tersebut. Skenario kelima adalah pengujian performa dengan mengukur waktu respons sistem dari saat pengguna menekan tombol analisis hingga hasil rekomendasi ditampilkan, mencakup waktu panggilan API BMKG, waktu inferensi model, dan waktu rendering halaman hasil. Seluruh skenario pengujian menghasilkan *output* yang sesuai dengan spesifikasi yang ditetapkan, mengkonfirmasi bahwa implementasi sistem telah berhasil memenuhi seluruh persyaratan fungsional.

3.6.2. Pengujian Validasi Rekomendasi

Pengujian validasi rekomendasi dilakukan untuk menilai sejauh mana rekomendasi yang dihasilkan oleh sistem konsisten dengan pengetahuan agronomi yang telah mapan. Pengujian ini menggunakan sepuluh skenario kondisi cuaca dan tanah yang dipilih berdasarkan rentang nilai yang dikenal secara ilmiah sebagai kondisi optimal atau sub-optimal untuk jenis tanaman tertentu. Sebagai contoh, pada kondisi suhu 23 derajat Celsius, kelembapan 71 persen, dan *ph* 6,5, yang merupakan kondisi mendekati optimal untuk jagung (*maize*) berdasarkan literatur agronomi, sistem memberikan rekomendasi jagung dengan probabilitas sebesar 0,88 atau 88 persen. Pada kondisi suhu 18 derajat Celsius, kelembapan 63 persen, dan *ph* 5,8, yang mendekati kondisi optimal untuk kentang (*potato*) berdasarkan literatur, sistem memberikan rekomendasi kentang dengan probabilitas 0,55 yang mencerminkan ketidakpastian model dalam membedakan kentang dan tomat sebagaimana telah dibahas sebelumnya.

Dari sepuluh skenario yang diuji, delapan skenario menghasilkan rekomendasi yang konsisten dengan pengetahuan agronomi yang menjadi referensi, sementara dua skenario menghasilkan rekomendasi yang berbeda namun masih dapat dibenarkan secara ilmiah karena kondisi yang diuji berada di perbatasan antara zona optimal dua jenis tanaman yang berbeda. Tingkat konsistensi sebesar 80 persen antara rekomendasi sistem dan referensi agronomi ini selaras dengan nilai akurasi model sebesar 80,625 persen yang diperoleh dari evaluasi pada data uji, mengkonfirmasi bahwa evaluasi model pada data uji merupakan estimasi yang cukup akurat terhadap performa model dalam kondisi penggunaan nyata. Konsistensi antara performa *in-sample* (pada data uji) dan *out-of-sample* (pada skenario validasi) ini juga mengindikasikan bahwa model tidak mengalami *overfitting* terhadap data latih, yang merupakan salah satu keunggulan utama dari algoritma *Random Forest* berkat mekanisme *bagging* yang digunakannya.

3.7. Pembahasan Kelebihan dan Keterbatasan Sistem

3.7.1. Kelebihan Sistem

Sistem yang dikembangkan memiliki sejumlah kelebihan yang membedakannya dari pendekatan konvensional dalam pemberian rekomendasi perkebunan. Kelebihan pertama adalah kemampuan integrasi data *real-time* yang memungkinkan sistem untuk memberikan rekomendasi yang selalu relevan dengan kondisi cuaca aktual di lokasi pengguna, bukan hanya berdasarkan data historis yang mungkin tidak mencerminkan kondisi saat ini. Kemampuan ini merupakan pembeda utama dari sistem rekomendasi perkebunan berbasis tabel atau buku panduan konvensional yang tidak dapat memperbarui rekomendasinya secara dinamis. Kelebihan kedua adalah skalabilitas arsitektur *Data Warehouse* yang memungkinkan penambahan dataset baru, jenis tanaman baru, maupun fitur prediksi baru tanpa harus mengubah struktur sistem secara fundamental, cukup dengan memperbarui tabel dimensi dan tabel fakta serta melatih ulang model dengan data yang diperbarui.

Kelebihan ketiga adalah transparansi prediksi melalui penyajian probabilitas untuk seluruh kelas tanaman, yang memberikan pengguna kemampuan untuk memahami tingkat keyakinan sistem dan membuat keputusan yang lebih terinformasi dibandingkan sistem kotak hitam yang hanya memberikan satu jawaban tunggal tanpa indikasi ketidakpastian. Transparansi ini sejalan dengan prinsip *explainable artificial intelligence*

(XAI) yang semakin mendapat perhatian dalam pengembangan sistem berbasis kecerdasan buatan untuk aplikasi kritis (Arrieta et al., 2020). Kelebihan keempat adalah kemudahan akses melalui antarmuka web berbasis browser yang tidak memerlukan instalasi perangkat lunak khusus oleh pengguna, memungkinkan akses dari berbagai perangkat termasuk *smartphone* yang merupakan perangkat yang paling umum dimiliki oleh petani Indonesia saat ini.

3.7.2. Keterbatasan Sistem

Di samping kelebihan, sistem ini juga memiliki beberapa keterbatasan yang penting untuk dipahami agar pengguna dapat menggunakan dan menginterpretasikan hasil rekomendasi dengan tepat. Keterbatasan pertama adalah cakupan tanaman yang terbatas pada delapan jenis komoditas saja, yang merupakan konsekuensi langsung dari dataset yang digunakan. Banyak tanaman penting dalam konteks perkebunan Indonesia seperti padi, singkong, ubi jalar, kedelai, dan berbagai jenis sayuran lainnya belum tercakup dalam sistem ini. Ekspansi cakupan tanaman akan membutuhkan pengumpulan dataset tambahan yang mencakup spesifikasi iklim dan tanah untuk tanaman-tanaman tersebut, yang merupakan rencana pengembangan untuk iterasi sistem berikutnya.

Keterbatasan kedua adalah ketergantungan sistem terhadap ketersediaan dan akurasi data API BMKG. Jika layanan API BMKG mengalami gangguan atau data untuk suatu wilayah tidak tersedia, sistem tidak dapat memberikan rekomendasi berbasis cuaca aktual dan harus bergantung pada *input* manual pengguna yang mungkin kurang akurat. Keterbatasan ketiga adalah model yang hanya menggunakan tiga fitur prediksi (suhu, kelembapan, dan *ph*), sementara keberhasilan perkebunan dalam kenyataannya dipengaruhi oleh banyak faktor lain yang tidak dimodelkan seperti kandungan nutrisi tanah, ketersediaan air irigasi, topografi lahan, dan kondisi hama penyakit. Keterbatasan ini perlu dikomunikasikan dengan jelas kepada pengguna agar mereka tidak mengandalkan rekomendasi sistem secara eksklusif tanpa mempertimbangkan faktor-faktor kontekstual lain yang relevan dengan kondisi spesifik lahan mereka. Pengembangan sistem ke depan dapat mempertimbangkan penambahan fitur-fitur tersebut melalui integrasi dengan sumber data tambahan seperti data satelit tanah, data irigasi, dan data epidemiologi hama yang tersedia secara publik.

BAB IV

IMPLEMENTASI DAN TAMPILAN PROGRAM

4.1. Lingkungan Implementasi

Sistem AgroSense dikembangkan dan dijalankan dalam lingkungan implementasi yang mencakup komponen perangkat keras dan perangkat lunak yang saling terintegrasi. Dari sisi perangkat lunak, sistem dibangun menggunakan *Python* sebagai bahasa pemrograman utama untuk komponen *backend* dan pemrosesan *Machine Learning*, dengan *framework web Flask* sebagai fondasi pengelolaan *routing* HTTP. Pustaka *scikit-learn* digunakan untuk memuat dan mengeksekusi model *Random Forest Classifier* yang telah dilatih, sementara *pandas* dan *NumPy* menangani manipulasi data dan komputasi numerik. Pustaka *requests* digunakan untuk komunikasi dengan API BMKG, dan *joblib* untuk serialisasi serta deserialisasi model *Machine Learning*. Pada sisi *frontend*, sistem menggunakan HTML5, CSS3, dan *JavaScript* ES6 yang dikombinasikan dengan pustaka *Chart.js* untuk *rendering* grafik interaktif, serta mengimplementasikan desain sistem berbasis warna bertema perkebunan yang didominasi palet hijau-kuning cerah (*chartreuse*) dan hitam sebagai warna kontras utama.

Sistem yang dihasilkan diberi nama AgroSense, sebuah platform Business Intelligence perkebunan berbasis web yang dapat diakses melalui browser pada perangkat desktop maupun mobile. Nama AgroSense mencerminkan dua konsep inti yang menjadi landasan sistem, yaitu kata “Agro” yang merujuk pada domain perkebunan (agrikultur) dan kata “Sense” yang merujuk pada kemampuan sistem untuk mendeteksi dan memahami (*sensing*) kondisi lingkungan secara cerdas melalui integrasi data cuaca *real-time* dan kecerdasan buatan. Sistem ini terdiri dari tujuh halaman utama yang dapat diakses pengguna, yaitu Beranda, Cuaca, Analisis Tanaman, Data Historis, Laporan, Masuk (*Login*), dan Daftar (*Register*), yang keseluruhannya dihubungkan oleh *navigation* bar yang konsisten di setiap halaman dan dirancang untuk memberikan pengalaman navigasi yang intuitif dan efisien bagi seluruh segmen pengguna.

Identitas visual AgroSense dibangun di atas sistem desain yang konsisten dan kohesif di seluruh halaman. Palet warna utama yang digunakan adalah warna latar belakang krem atau *off-white* (#F5F5EF) untuk menciptakan nuansa yang hangat dan

alami, dikombinasikan dengan warna aksen kuning-hijau cerah (*chartreuse*, #C8FF00 atau variannya) sebagai warna *call-to-action* dan elemen interaktif utama, serta warna hitam pekat (#1A1A1A) sebagai warna teks dan border elemen kartu untuk menciptakan kontras yang tinggi dan keterbacaan yang optimal. Sistem tipografi menggunakan *font sans-serif* modern yang bersih untuk keseluruhan teks antarmuka, menciptakan kesan profesional sekaligus mudah dibaca pada berbagai ukuran layar. Konsistensi visual ini merupakan implementasi dari prinsip *design system* yang menyatakan bahwa komponen antarmuka yang digunakan secara konsisten di seluruh produk menciptakan pengalaman pengguna yang terprediksi dan mudah dipelajari (Fanguy, 2019).

4.2. Tampilan Halaman Beranda (Homepage)


4.2.1. Deskripsi Umum Halaman Beranda

Halaman Beranda merupakan halaman pertama yang ditampilkan kepada pengguna saat mengakses platform AgroSense dan berfungsi sebagai gerbang utama yang memperkenalkan seluruh kapabilitas sistem secara menyeluruh sebelum pengguna menavigasi ke halaman-halaman fungsional yang lebih spesifik. Sebagaimana terlihat pada Gambar 4.1, halaman ini dirancang dengan pendekatan *single-page scrolling* yang memuat seluruh informasi penting dalam satu halaman panjang yang dapat dinavigasi secara vertikal, menghindari kebutuhan pengguna untuk berpindah ke halaman lain hanya untuk mendapatkan gambaran umum sistem. Pendekatan ini konsisten dengan tren desain web modern yang memprioritaskan kemudahan eksplorasi konten secara linier tanpa memutus alur pengalaman pengguna (Wroblewski, 2011).

Navigation bar di bagian paling atas halaman menampilkan logo dan nama “AgroSense” di sisi kiri, diikuti oleh lima tombol navigasi utama yang diberi label Beranda, Cuaca, Analisis Tanaman, Data Historis, dan Laporan, serta tombol *dropdown* “Akun” di sisi kanan untuk akses ke fitur autentikasi. Tombol navigasi yang sedang aktif ditandai dengan latar belakang kuning-hijau cerah yang kontras, dalam hal ini tombol “Beranda” yang berwarna kuning-hijau menunjukkan halaman yang sedang aktif, sementara tombol lainnya memiliki latar belakang transparan. Sistem penanda navigasi aktif ini merupakan implementasi dari prinsip *visibility of system status* yang dikemukakan oleh Nielsen (1994), yang menyatakan bahwa sistem yang baik harus selalu menginformasikan kepada pengguna mengenai kondisi sistem saat ini, termasuk halaman

mana yang sedang mereka kunjungi.

4.2.2. Elemen-elemen Halaman Beranda



Gambar 4.1. Tampilan Halaman Beranda AgroSense

Bagian pertama dari halaman Beranda adalah hero section yang menampilkan judul utama dalam tipografi berukuran sangat besar dengan teks “Cari Tahu Kesesuaian

Tanaman & Cuaca.” yang dicetak tebal dan mencolok di sisi kiri, dipadukan dengan foto panorama lahan perkebunan dengan langit keemasan di sisi kanan. Teks judul menggunakan ukuran font yang sangat besar (kurang lebih setara 56px) dengan ketebalan font-weight 800 yang menciptakan hierarki visual yang sangat jelas, menjadikan proposisi nilai utama sistem sebagai hal pertama yang dibaca oleh pengguna. Di bawah judul terdapat teks deskripsi singkat yang menjelaskan bahwa “AgroSense membantu Anda menganalisis kesesuaian tanaman berdasarkan cuaca terkini, melihat data historis, serta menyusun laporan untuk pengambilan keputusan yang lebih baik.” Dua tombol call-to-action berdampingan yaitu “Mulai Analisis” berwarna kuning-hijau dan “Pelajari Lebih” berwarna transparan dengan border hitam melengkapi hero section, memberikan pengguna dua jalur interaksi yang jelas sesuai dengan tingkat kesiapan mereka untuk langsung menggunakan sistem.

Bagian kedua adalah section “Tiga Langkah Sederhana” yang menjelaskan alur penggunaan sistem dalam tiga tahap berurutan yang disajikan dalam tiga kartu horizontal dengan nomor urut yang eksplisit. Langkah pertama berlabel “1. Pantau Cuaca” menjelaskan bahwa pengguna dapat melihat suhu, kelembapan, curah hujan, dan kecepatan angin secara real-time dari lokasi mereka. Langkah kedua berlabel “2. Analisis Tanaman” menjelaskan bahwa sistem akan menghitung skor kesesuaian untuk delapan jenis tanaman berdasarkan data cuaca aktual dan menemukan tanaman yang paling cocok. Langkah ketiga berlabel “3. Hasil & Laporan” menjelaskan bahwa pengguna dapat mengakses data historis dalam bentuk grafik interaktif serta laporan yang siap diekspor. Penyajian alur penggunaan dalam format tiga langkah bernomor ini merupakan teknik onboarding yang efektif karena mereduksi persepsi kompleksitas sistem dengan memecah proses yang mungkin terasa rumit menjadi serangkaian langkah yang terasa mudah dan terpandu (Lichaw, 2016).

Bagian ketiga adalah section “Fitur Andalan” yang menampilkan lima kartu fitur dalam tata letak grid dua kolom dengan satu kartu penuh di bagian bawah. Kelima kartu tersebut adalah kartu “Pantauan Cuaca” berlatar belakang kuning-hijau yang menjelaskan fitur pemantauan suhu, kelembapan, curah hujan, dan angin secara real-time dalam tampilan grafik interaktif; kartu “Analisis Tanaman” berlatar belakang biru cyan yang menjelaskan fitur penghitungan skor kesesuaian untuk delapan jenis tanaman; kartu “Data Historis” berlatar belakang abu-abu yang menjelaskan fitur penjelajahan data cuaca tujuh

hari terakhir dengan grafik per metrik; kartu “Laporan & Ekspor” berlatar belakang abu-abu yang menjelaskan fitur akses dashboard KPI dan ekspor data; serta kartu “Deteksi Lokasi Otomatis” berlatar belakang kuning-hijau penuh yang menjelaskan kemampuan sistem untuk menggunakan lokasi pengguna saat ini secara otomatis. Penggunaan warna latar belakang yang berbeda-beda pada kartu fitur ini bukan sekadar pilihan estetis, melainkan merupakan strategi visual untuk membedakan tingkat kepentingan atau kategori setiap fitur, membantu pengguna dalam mengidentifikasi dan mengingat fitur-fitur yang paling relevan dengan kebutuhan mereka.

Bagian keempat adalah section “Wawasan Agro” yang menampilkan tiga kartu insight otomatis berbasis analisis sistem, yaitu kartu “18% Risiko Penyakit Rendah” yang menjelaskan bahwa kelembapan stabil dan sirkulasi udara yang cukup menguntungkan untuk tujuh hari ke depan, kartu “+21% Efisiensi Irigasi” yang menjelaskan bahwa penjadwalan irigasi malam hari dapat menekan penguapan secara signifikan, dan kartu “8.9 t/ha Prediksi Panen” yang menunjukkan prediksi hasil panen yang 0,5 t/ha di atas rata-rata tanaman sebelumnya di blok selatan. Ketiga insight ini merepresentasikan output analitik tingkat tinggi dari sistem Business Intelligence yang secara proaktif menyajikan temuan-temuan penting kepada pengguna tanpa mengharuskan mereka melakukan kueri atau analisis manual, sebuah karakteristik yang membedakan sistem BI modern dari sistem pelaporan konvensional yang bersifat pasif (Eckerson, 2010).


Bagian terakhir adalah section penutup “Siap Memulai?” yang menampilkan latar belakang kartu hitam dengan foto perkebunan, teks undangan untuk memulai penggunaan sistem, dan dua tombol “Mulai Sekarang” serta “Jelajahi Fitur”. Section ini berfungsi sebagai pengingat call-to-action terakhir setelah pengguna selesai menjelajahi seluruh konten halaman Beranda, mengantisipasi pengguna yang membutuhkan waktu lebih lama untuk membuat keputusan penggunaan setelah membaca seluruh informasi yang tersedia di halaman ini.

4.3. Tampilan Halaman Cuaca

4.3.1. Deskripsi Umum Halaman Cuaca

Halaman Cuaca merupakan halaman kedua dalam navigasi utama AgroSense dan berfungsi sebagai pusat informasi meteorologi yang menyajikan data cuaca real-time dan

prakiraan dari API BMKG dalam format yang kaya dan komprehensif. Sebagaimana terlihat pada Gambar 4.2, halaman ini menampilkan informasi cuaca untuk lokasi yang terdeteksi secara otomatis, yaitu Jakarta pada contoh screenshot yang tersedia, dengan timestamp analisis yang menunjukkan tanggal dan waktu pembaruan data terakhir. Tombol “Refresh” berwarna kuning-hijau di sudut kanan atas header memungkinkan pengguna untuk memperbarui data cuaca secara manual kapan saja tanpa harus me-reload seluruh halaman, mengimplementasikan konsep progressive loading yang menjaga pengalaman pengguna tetap mulus.



Gambar 4.2. Tampilan Halaman Cuaca AgroSense

4.3.2. Elemen-elemen Halaman Cuaca

Panel informasi cuaca utama yang berada di bagian atas konten halaman menampilkan data cuaca terkini dalam format yang padat namun mudah dibaca. Latar

belakang panel ini menggunakan warna kuning-hijau cerah yang konsisten dengan identitas visual AgroSense, menciptakan penekanan visual yang kuat untuk data cuaca yang merupakan informasi paling penting di halaman ini. Bagian kiri panel menampilkan nama kota “Jakarta” berwarna oranye yang mencolok, diikuti timestamp analisis, sementara bagian kanan menampilkan suhu saat ini sebesar 26 derajat Celsius dengan ikon tetesan air dan label “Hujan Ringan” sebagai deskripsi kondisi cuaca umum dalam ukuran font yang besar dan tegas.

Di bawah informasi suhu utama, terdapat delapan kartu data cuaca sekunder yang tersusun dalam grid dua baris empat kolom, masing-masing menampilkan satu parameter meteorologi beserta ikonnya. Kedelapan parameter tersebut adalah Kelembapan sebesar 89 persen, Curah Hujan sebesar 1,3 mm, Angin sebesar 9,6 km/jam, rentang Suhu Min/Max antara 25 dan 26 derajat Celsius, Heat Index sebesar 26 derajat Celsius, Dew Point sebesar 24 derajat Celsius, Arah Angin ke arah Utara (N), dan Kondisi umum Hujan Ringan. Kelengkapan parameter cuaca yang disajikan ini melampaui data yang umum tersedia pada aplikasi cuaca konsumen biasa, dan secara khusus relevan untuk keperluan perkebunan karena parameter seperti heat index, dew point, dan arah angin memiliki implikasi agronomi yang signifikan terhadap kesehatan tanaman dan efisiensi irigasi.

Bagian tengah halaman menampilkan tiga grafik time-series yang disusun dalam kolom kiri dan satu panel citra satelit di kolom kanan. Grafik pertama berlabel “Suhu & Kelembapan (3-Jam)” menampilkan dua garis berwarna berbeda dalam satu bidang koordinat, yaitu garis merah-oranye untuk suhu dan garis biru muda untuk kelembapan, dengan sumbu horizontal menunjukkan timestamp tiga jam dari tanggal 11 hingga 13 Mei 2026. Dari grafik ini terlihat bahwa suhu berfluktuasi dalam rentang sekitar 23 hingga 31 derajat Celsius sepanjang periode yang ditampilkan, sementara kelembapan cenderung tinggi dan stabil di sekitar 80 hingga 98 persen. Grafik kedua berlabel “Curah Hujan (3-Jam)” menampilkan bar chart vertikal berwarna biru yang menunjukkan distribusi curah hujan per tiga jam, dengan nilai tertinggi mencapai sekitar 1,8 mm yang terjadi pada periode tertentu. Grafik ketiga berlabel “Kecepatan Angin (3-Jam)” menampilkan garis berwarna hijau yang berfluktuasi menunjukkan variasi kecepatan angin sepanjang periode pengamatan dalam satuan km/jam.

Panel citra satelit di kolom kanan merupakan fitur yang sangat menonjol dan membedakan AgroSense dari aplikasi cuaca perkebunan lainnya. Panel ini menampilkan

citra satelit Himawari-9 EH (Enhanced Rainfall Potential) dari BMKG dengan timestamp 11/05/2026 11:00 UTC, yang memperlihatkan kondisi awan dan potensi hujan di seluruh wilayah Indonesia dan sekitarnya dalam representasi warna semu (false color) dengan skala warna yang menunjukkan intensitas curah hujan potensial dari biru muda (rendah) hingga merah (sangat tinggi). Integrasi citra satelit langsung dari sumber resmi BMKG ke dalam antarmuka AgroSense memberikan nilai tambah yang sangat signifikan bagi pengguna yang membutuhkan pemahaman spasial mengenai kondisi cuaca regional, terutama petani yang lahannya terletak di wilayah yang rentan terhadap cuaca ekstrem.


Bagian bawah halaman Cuaca terdiri dari dua panel prakiraan, yaitu panel “24 Jam ke Depan” yang menampilkan delapan kartu prakiraan per tiga jam dengan ikon cuaca, suhu, dan curah hujan masing-masing, serta panel “Prakiraan 3 Hari” yang menampilkan kartu prakiraan untuk hari ini (Senin, Hujan Ringan, 26 derajat Celsius, RH 90%, curah hujan 3mm, angin 7,8 km/jam), esok hari Selasa (Cerah, 32 derajat Celsius, RH 83%, curah hujan 1,6 mm, angin 3,5 km/jam), dan lusa Rabu (Cerah, 31 derajat Celsius, RH 83%, curah hujan 0,4 mm, angin 5,5 km/jam). Kartu untuk hari ini mendapat penekanan visual dengan latar belakang kuning-hijau yang membedakannya dari kartu hari berikutnya. Di bagian paling bawah halaman terdapat panel “Sumber Data” yang secara transparan mencantumkan bahwa data prakiraan cuaca bersumber dari BMKG melalui API publik dan diperbarui dua kali sehari, beserta timestamp waktu analisis terakhir.

4.4. Tampilan Halaman Analisis Tanaman

4.4.1. Deskripsi Umum Halaman Analisis Tanaman

Halaman Analisis Tanaman merupakan inti fungsional dari platform AgroSense dan merupakan halaman di mana seluruh komponen sistem, yaitu Data Warehouse, model Machine Learning Random Forest, dan data cuaca real-time BMKG, bekerja bersama untuk menghasilkan output utama sistem berupa skor kesesuaian tanaman beserta rekomendasi dan insight agronomi yang terperinci. Sebagaimana terlihat pada Gambar 4.3, halaman ini menampilkan hasil analisis untuk tanaman Pisang di lokasi Samarinda (Kecamatan Samarinda Ulu) yang dianalisis pada 11 Mei 2026 pukul 19.17. Panel header halaman menampilkan judul “Hasil Analisis Kesesuaian” dengan subjudul yang menyebutkan secara eksplisit nama tanaman dan lokasi yang dianalisis, memberikan

konteks yang jelas dan spesifik kepada pengguna. Di bawah judul terdapat empat elemen informasi dalam format pill-shaped yang menampilkan Lokasi, Tanaman, Waktu Analisis, dan tombol “Analisis Ulang” berwarna hijau tua, yang memungkinkan pengguna untuk dengan mudah melakukan analisis baru tanpa harus menavigasi ulang dari halaman awal.



Gambar 4.3. Tampilan Halaman Analisis Tanaman AgroSense

4.4.2. Panel Tingkat Kesesuaian

Panel pertama dan paling krusial pada halaman ini adalah panel “Tingkat Kesesuaian” yang menampilkan skor kesesuaian dalam angka persentase besar berwarna kuning-oranye, yaitu 52 persen, yang dikategorikan sebagai “Waspada” dalam warna yang sama. Di bawah angka persentase terdapat teks penjelas naratif yang menyatakan bahwa kesesuaian cuaca hari ini untuk Pisang perlu diwaspadai karena suhu 27 derajat Celsius dan kelembapan 94 persen perlu dipantau, serta risiko iklim tiga hari ke depan tergolong sedang. Sistem kategorisasi tiga tingkat yang digunakan AgroSense adalah Optimal (ditandai dengan warna hijau), Waspada (ditandai dengan warna kuning-oranye), dan Kurang Sesuai (ditandai dengan warna merah), yang dapat dilihat konsistensinya di halaman Laporan. Sistem kategorisasi ini merupakan implementasi dari pendekatan traffic light reporting yang umum digunakan dalam dashboard Business Intelligence

karena kemampuannya untuk mengkomunikasikan status secara instan melalui kode warna yang bersifat universal (Few, 2006).

4.4.3. Panel Kondisi Cuaca dan Rekomendasi Alternatif

Amsax Panel kedua yang berdampingan dengan panel kesesuaian adalah panel “Kondisi Cuaca” yang menampilkan data cuaca aktual yang digunakan sebagai basis analisis, yaitu suhu 27 derajat Celsius dengan kondisi Berawan, kelembapan 92 persen, curah hujan 0 mm, kecepatan dan arah angin SW 1,2 km/jam, serta nilai pH Tanah 6,5. Penyertaan nilai pH tanah dalam panel ini mengkonfirmasi bahwa sistem mengintegrasikan parameter tanah ke dalam analisis bersama data cuaca dari BMKG, sebagaimana dirancang dalam arsitektur Data Warehouse dengan tabel `dim_soil` yang telah dijelaskan pada Bab 2.

Panel ketiga adalah panel “Rekomendasi Alternatif” yang menampilkan lima tanaman alternatif berikut skor kesesuaiannya masing-masing dalam format daftar bernomor dengan progress bar horizontal berwarna yang mencerminkan tingkat kesesuaian. Kelima alternatif tersebut adalah Jeruk dengan skor 82 persen (progress bar hijau), Pepaya dengan skor 78 persen (progress bar hijau), Semangka dengan skor 55 persen (progress bar kuning-oranye), Kacang Hijau dengan skor 54 persen (progress bar kuning-oranye), dan Kentang dengan skor 28 persen (progress bar merah). Hasil ini secara langsung merepresentasikan output dari metode `predict_proba()` model Random Forest yang diurutkan berdasarkan nilai probabilitas tertinggi, dan konsisten dengan temuan evaluasi model yang menunjukkan bahwa Jeruk (orange) dan Pepaya (papaya) memiliki F1-score yang tinggi, mengindikasikan bahwa model dapat mengidentifikasi kedua tanaman tersebut dengan keyakinan yang baik.

4.4.4. Panel Insight dan Skor Kesesuaian Harian

Bagian bawah halaman Analisis Tanaman terdiri dari dua panel tambahan yang memberikan kedalaman analisis yang lebih komprehensif melampaui sekadar angka skor tunggal. Panel “Insight untuk Pisang” menampilkan tiga kartu insight agronomi yang masing-masing membahas satu dimensi risiko, yaitu kartu Stres Panas berkategori “Sedang” yang menjelaskan bahwa suhu maksimum 31 derajat Celsius mendekati batas optimal 29,9 derajat Celsius sehingga perlu dipantau, kartu Risiko Penyakit berkategori “Sedang” yang menjelaskan bahwa kelembapan 90 persen sedikit di atas ideal sehingga


pengguna perlu waspada terhadap embun dan jamur daun, serta kartu Ketersediaan Air berkategori “Kurang” yang menjelaskan bahwa curah hujan 2,7 mm per tiga hari berada di bawah ideal sehingga irigasi tambahan dianjurkan. Ketiga kartu ini memiliki indikator progress bar horizontal yang memvisualisasikan level risiko dari rendah ke tinggi, memberikan representasi visual yang memperkuat pesan tekstual yang disampaikan.

Panel “Skor Kesesuaian Harian” menampilkan tiga kartu prakiraan kesesuaian untuk tiga hari ke depan secara berdampingan, yang merupakan fitur unik yang mengintegrasikan data prakiraan cuaca tiga hari dari BMKG dengan model Machine Learning untuk menghasilkan prediksi kesesuaian yang bersifat temporal. Kartu Hari ke-1 (Senin, 11 Mei) menampilkan skor 52 persen berkategori Waspada dengan latar kuning, kartu Hari ke-2 (Selasa, 12 Mei) menampilkan skor 69 persen berkategori Optimal dengan latar hijau muda, dan kartu Hari ke-3 (Rabu, 13 Mei) menampilkan skor 72 persen berkategori Optimal juga dengan latar hijau muda. Setiap kartu dilengkapi dengan detail suhu, kelembapan, serta dua progress bar yang menunjukkan persentase kesesuaian suhu dan kelembapan secara terpisah. Tren peningkatan skor dari 52 persen pada hari pertama menjadi 72 persen pada hari ketiga memberikan informasi strategis yang sangat berharga bagi petani dalam merencanakan waktu tanam yang optimal.

4.5. Tampilan Halaman Data Historis

4.5.1. Deskripsi Umum Halaman Data Historis

Halaman Data Historis merupakan halaman keempat dalam navigasi utama AgroSense yang berfungsi sebagai repositori dan visualisasi interaktif untuk data cuaca historis berbasis waktu yang bersumber dari BMKG. Sebagaimana terlihat pada Gambar 4.4, halaman ini menampilkan data historis cuaca untuk lokasi Samarinda dengan resolusi tiga jam. Bagian header halaman menampilkan judul “Data Historis Cuaca” dengan subjudul “Data cuaca detail dari BMKG dengan resolusi 3 jam.” Di bawah header terdapat dua elemen kontrol, yaitu field input lokasi yang telah terisi dengan nilai “Samarinda” dan dropdown filter Metrik yang menampilkan pilihan “Semua Metrik”, serta tombol “Deteksi Ulang Lokasi” berwarna kuning-hijau yang memungkinkan pengguna memperbarui lokasi secara otomatis menggunakan geolokasi perangkat mereka.



Gambar 4.4. Tampilan Halaman Data Historis AgroSense

4.5.2. Panel Klasifikasi dan Kecenderungan

Halaman Data Historis dibagi menjadi tiga area konten utama. Area pertama adalah panel rangkuman yang terdiri dari dua panel berdampingan. Panel “Klasifikasi Curah Hujan” menampilkan ringkasan statistik kejadian hujan selama periode 11 hingga 13 Mei 2026 dalam format empat kartu metrik berwarna, yaitu 17 kejadian hujan Ringan (warna biru), 0 kejadian hujan Sedang (warna kuning), 0 kejadian hujan Lebat (warna oranye), dan 0 kejadian hujan Ekstrem (warna merah), dengan total 10 kejadian hujan dan total curah hujan 3,3 mm. Panel “Kecenderungan (3 Hari Terakhir)” menampilkan ringkasan nilai rata-rata empat parameter utama dalam format daftar, yaitu Suhu rata-rata 26,8 derajat Celsius, Kelembapan rata-rata 89,8 persen, Curah Hujan rata-rata 0,2 mm, dan Angin rata-rata 5,5 km/jam. Setiap baris dilengkapi dengan ikon tanda panah yang

menunjukkan arah kecenderungan (naik, turun, atau stabil) berdasarkan perbandingan dengan periode sebelumnya.

4.5.3. Panel Semua Metrik dan Rincian Per Hari

Area kedua adalah panel “Semua Metrik” yang menampilkan empat grafik time-series dalam tata letak grid dua kolom dua baris. Grafik pertama berlabel “Suhu (°C)” menampilkan garis berwarna merah-oranye yang memperlihatkan fluktuasi suhu dari tanggal 11 hingga 13 Mei 2026 dengan nilai maksimum 31 derajat Celsius yang ditampilkan di sudut kanan atas grafik. Grafik kedua berlabel “Kelembapan (%)” menampilkan garis berwarna biru muda yang memperlihatkan fluktuasi kelembapan dengan nilai maksimum 98 persen. Grafik ketiga berlabel “Curah Hujan (mm)” menampilkan garis berwarna biru-cyan yang memperlihatkan pola curah hujan dengan nilai maksimum 1,4 mm. Grafik keempat berlabel “Kecepatan Angin (km/h)” menampilkan garis berwarna hijau yang memperlihatkan variasi kecepatan angin dengan nilai maksimum 9,8 km/jam. Keempat grafik menggunakan sumbu horizontal yang seragam dengan format timestamp yang konsisten, memudahkan perbandingan visual antar parameter secara simultan.


Area ketiga adalah panel “Rincian Per Hari” yang menyajikan data cuaca historis dalam format yang dapat diperluas (expandable) per hari. Pada screenshot yang tersedia, baris Senin 11 Mei dan Selasa 12 Mei ditampilkan dalam kondisi terlipat (collapsed) yang hanya menampilkan ringkasan kelembapan dan rentang suhu, sementara baris Rabu 13 Mei ditampilkan dalam kondisi terbuka (expanded) yang menampilkan delapan kartu data per tiga jam, mencakup jam 00:00 (25°C, RH 97%, angin 6,4 km/jam), 03:00 (25°C, RH 98%, angin 5,6 km/jam), 06:00 (25°C, RH 95%, angin 6,8 km/jam), 09:00 (29°C, RH 77%, curah hujan 0,1 mm, angin 5,7 km/jam), 12:00 (31°C, RH 72%, curah hujan 0,1 mm, angin 0,4 km/jam), 15:00 (29°C, RH 82%, curah hujan 1,4 mm, angin 8,7 km/jam), 18:00 (27°C, RH 93%, curah hujan 0,5 mm, angin 2,2 km/jam), dan 21:00 (26°C, RH 96%, angin 4 km/jam).

4.6. Tampilan Halaman Laporan

4.6.1. Deskripsi Umum Halaman Laporan

Halaman Laporan merupakan halaman kelima dalam navigasi utama AgroSense yang berfungsi sebagai dashboard ringkasan eksekutif dan riwayat analisis yang telah

dilakukan oleh pengguna. Sebagaimana terlihat pada Gambar 4.5, halaman ini dibagi menjadi dua bagian utama yaitu “Dashboard Ringkasan” di bagian atas dan “Riwayat Analisis” di bagian bawah. Halaman ini memiliki orientasi yang jelas sebagai alat pelaporan dan audit yang memungkinkan pengguna untuk memantau tren kesesuaian tanaman secara historis dan mengambil keputusan berdasarkan akumulasi analisis yang telah dilakukan sebelumnya.



Gambar 4.5. Tampilan Halaman Laporan AgroSense

4.6.2. Panel Dashboard Ringkasan

Panel Dashboard Ringkasan menampilkan empat kartu KPI (Key Performance Indicator) dalam satu baris horizontal di bawah judul yang mencantumkan lokasi “Samarinda” dan periode “11 Mei hingga 13 Mei”. Kartu pertama menampilkan “Suhu Rata-rata” dengan nilai 26°C yang diilustrasikan dengan mini sparkline grafik garis berwarna oranye. Kartu kedua menampilkan “Curah Hujan (7 Hari)” dengan nilai 3,3 mm yang diilustrasikan dengan mini sparkline grafik garis berwarna biru. Kartu ketiga menampilkan “Tanaman Terbaik” dengan nilai “Jeruk” berwarna hijau dan keterangan “Skor 77%”. Kartu keempat menampilkan “Analisis Tersimpan” dengan nilai angka 8

dan keterangan “Riwayat analisis”. Penyajian KPI dalam format kartu numerik dengan sparkline merupakan pendekatan yang lazim dalam desain dashboard eksekutif karena memungkinkan pemantauan nilai kunci secara sekilas tanpa memerlukan pembacaan grafik yang lebih detail (Few, 2006).

Di bawah keempat kartu KPI terdapat panel Insight yang menampilkan tiga butir temuan otomatis berbasis analisis data, yaitu “Kelembapan rata-rata 90% cukup tinggi — waspada risiko penyakit jamur”, “Curah hujan total 3,3 mm rendah — tanaman mungkin memerlukan irigasi tambahan”, dan “Tanaman terbaik: Jeruk dengan skor 77%”. Ketiga insight ini dihasilkan secara otomatis oleh sistem berdasarkan threshold yang telah ditetapkan untuk masing-masing parameter, dan berfungsi sebagai ringkasan naratif yang memudahkan pengguna dalam memahami kondisi perkebunan secara keseluruhan tanpa harus menginterpretasikan data mentah secara mandiri.

4.6.3. Panel Riwayat Analisis


Panel Riwayat Analisis menampilkan tabel terstruktur yang memuat seluruh analisis tanaman yang telah dilakukan pengguna, disusun secara kronologis dari yang terbaru. Tabel ini memiliki delapan kolom, yaitu nomor urut, Tanggal (format DD Mei YYYY, HH:MM), Tanaman, Lokasi, Skor (dalam badge berwarna), Kesesuaian (label kategori berwarna), Stres Panas, Risiko Penyakit, dan Ketersediaan Air. Dari delapan baris data yang tersedia, terlihat bahwa pengguna telah melakukan analisis untuk berbagai tanaman di Samarinda pada tanggal 11 Mei 2026, dengan hasil yang bervariasi. Tanaman Jeruk pada pukul 20.38 mendapatkan skor tertinggi sebesar 77 persen dengan kategori Optimal (hijau), diikuti Pepaya pada waktu yang sama dengan skor 70 persen berkategori Optimal. Tanaman Kacang Hijau mendapatkan skor 40 persen berkategori Waspada, Jagung mendapatkan skor 36 persen berkategori Waspada di tiga analisis berbeda, dan satu analisis Jagung pada pukul 19.37 mendapatkan skor terendah 33 persen dengan kategori “Kurang Sesuai” berwarna merah.

Di bagian atas tabel terdapat empat tombol aksi, yaitu “Segarkan” (refresh data), “JSON” (ekspor data dalam format JSON), “CSV” (ekspor data dalam format CSV), dan “Hapus Semua” (hapus seluruh riwayat) yang masing-masing menggunakan warna berbeda untuk membedakan fungsinya secara visual. Fitur ekspor ke format JSON dan CSV ini merupakan implementasi dari prinsip interoperabilitas data yang memungkinkan pengguna untuk menggunakan data analisis AgroSense dalam aplikasi lain seperti

spreadsheet atau sistem informasi perkebunan yang lebih besar, mewujudkan konsep open data yang mendukung ekosistem pengambilan keputusan berbasis data yang lebih luas (Zuiderwijk & Janssen, 2014).

4.7. Tampilan Halaman Masuk (Login)

Halaman Masuk merupakan halaman autentikasi yang dapat diakses melalui tombol “Akun” di navigation bar dan berfungsi untuk memverifikasi identitas pengguna yang telah memiliki akun terdaftar sebelum memberikan akses ke fitur-fitur sistem yang memerlukan sesi pengguna aktif, terutama fitur penyimpanan riwayat analisis pada halaman Laporan. Sebagaimana terlihat pada Gambar 4.6, halaman ini menampilkan desain kartu modal (modal card) yang berdiri sendiri di atas latar belakang off-white, dengan batas sudut yang membulat dan border hitam tebal yang konsisten dengan bahasa desain keseluruhan AgroSense.



Gambar 4.6. Tampilan Halaman Masuk (Login) AgroSense

Elemen-elemen halaman Masuk terdiri dari tautan “Kembali” di sudut kiri atas yang memungkinkan pengguna kembali ke halaman sebelumnya, ikon login berwarna kuning-hijau berbentuk kotak membulat dengan panah masuk di bagian tengah atas kartu, judul “Masuk” dalam tipografi berukuran besar dan tebal, serta subjudul “Silakan masuk ke akun Anda” yang memberi konteks kepada pengguna. Di bawahnya terdapat dua field input, yaitu field Email dengan placeholder “[contoh@email.com](#)” yang dilengkapi ikon

amplop di sisi kiri, dan field Password dengan placeholder “Masukkan password” yang dilengkapi ikon gembok di sisi kiri dan ikon mata di sisi kanan untuk toggle visibilitas password. Tombol “Masuk” berwarna kuning-hijau penuh dengan teks hitam tebal menempati seluruh lebar kartu untuk memaksimalkan area target klik. Di bagian paling bawah terdapat teks “Belum punya akun?” diikuti tautan “Daftar” yang mengarahkan pengguna ke halaman registrasi.

4.8. Tampilan Halaman Daftar (Register)

Halaman Daftar merupakan halaman registrasi yang memungkinkan pengguna baru untuk membuat akun AgroSense. Sebagaimana terlihat pada Gambar 4.7, halaman ini menggunakan desain kartu modal yang identik dengan halaman Masuk dalam hal tata letak dan struktur, namun dengan beberapa perbedaan visual yang membedakannya secara jelas. Ikon di bagian atas kartu menggunakan warna biru cyan dan menampilkan ikon penambahan pengguna (user-plus), berbeda dari ikon masuk berwarna kuning-hijau pada halaman Login, sehingga pengguna dapat mengidentifikasi perbedaan fungsional kedua halaman secara instan melalui perbedaan warna dan ikon tersebut.

Gambar 4.7. Tampilan Halaman Daftar (Register) AgroSense

Halaman Daftar memiliki tiga field input yang lebih banyak dibandingkan halaman Masuk, yaitu field Nama dengan placeholder “Nama lengkap” dan ikon pengguna, field Email dengan placeholder “[contoh@email.com](#)” dan ikon amplop, serta field Password dengan placeholder “Minimal 6 karakter” dan ikon gembok beserta toggle visibilitas. Persyaratan panjang password minimal enam karakter yang dicantumkan secara eksplisit

sebagai placeholder merupakan pendekatan yang baik dalam desain form karena memberikan panduan kepada pengguna secara proaktif sebelum mereka membuat kesalahan, mengurangi friksi dalam proses registrasi (Bargas-Avila & Hornbæk, 2011). Tombol “Daftar” menggunakan warna biru cyan yang berbeda dari tombol “Masuk” berwarna kuning-hijau, konsisten dengan penggunaan warna ikon yang berbeda untuk membedakan kedua halaman. Tautan “Sudah punya akun? Masuk” di bagian bawah memberikan jalur navigasi yang mudah bagi pengguna yang salah mengakses halaman registrasi padahal bermaksud untuk login.

4.9. Tampilan Executive Dashboard

4.9.1. Deskripsi Umum Executive Dashboard

Executive Executive Dashboard merupakan halaman eksklusif yang dirancang khusus untuk pengguna dengan hak akses tingkat administrator dan superadministrator, dan tidak dapat diakses oleh pengguna umum yang terdaftar sebagai pengguna reguler. Keberadaan halaman ini mencerminkan implementasi konsep Role-Based Access Control (RBAC) dalam sistem AgroSense, di mana hak akses terhadap fitur dan data tertentu dibatasi secara ketat berdasarkan peran yang dimiliki pengguna dalam sistem. Halaman ini terdiri dari tiga tab navigasi utama yaitu Performance Overview, Data Explorer, dan User Management, dengan tab yang sedang aktif ditandai latar belakang kuning-hijau yang konsisten dengan identitas visual keseluruhan platform AgroSense. Header panel selalu menampilkan nama lengkap dan alamat email pengguna yang sedang login di bawah judul Executive Dashboard, serta tombol Logout berwarna merah di sudut kanan atas untuk kemudahan keluar dari sesi administrator kapan pun diperlukan.

Sistem mengimplementasikan dua tingkatan akses yang berbeda dalam Executive Dashboard. Tingkat pertama adalah superadmin yang memiliki akses penuh terhadap ketiga tab termasuk tab User Management untuk mengelola seluruh akun administrator yang terdaftar dalam sistem. Tingkat kedua adalah admin reguler yang memiliki akses hanya terhadap tab Performance Overview dan Data Explorer, namun tidak dapat mengakses tab User Management. Perbedaan jumlah tab yang ditampilkan pada header panel menjadi penanda visual yang jelas bagi pengguna mengenai level aksesnya, sehingga tidak diperlukan notifikasi tambahan ketika pengguna mencoba mengakses fitur yang berada di luar wewenangnya. Desain ini menerapkan prinsip least privilege yang

memastikan setiap pengguna hanya diberikan akses minimum yang diperlukan untuk menjalankan fungsinya dalam sistem.

4.9.2. Tab Performance Overview



Gambar 4.8. Tampilan Executive Dashboard Tab Performance Overview

Tab Tab Performance Overview merupakan tab default yang pertama kali ditampilkan saat administrator membuka Executive Dashboard, baik untuk akun superadmin maupun akun admin reguler. Konten yang ditampilkan pada tab ini identik untuk kedua jenis akun, dengan perbedaan hanya pada nama dan email yang tercantum di header sesuai dengan akun yang sedang aktif. Bagian teratas tab ini adalah panel filter interaktif yang memungkinkan administrator memfilter seluruh data berdasarkan tiga dimensi sekaligus, yaitu Rentang Waktu dengan pilihan 7 Hari, 14 Hari, 30 Hari yang menjadi pilihan aktif pada screenshot, dan 90 Hari, kemudian filter Tanaman dengan default Semua Tanaman, serta filter Lokasi dengan default Semua Lokasi dalam format dropdown yang dapat diperluas. Di bawah panel filter terdapat empat kartu KPI yang masing-masing dilengkapi sparkline grafik mini di sisi kanan untuk menunjukkan tren nilai sepanjang periode aktif, yaitu kartu Total Analisis dengan nilai 36, kartu Rata-rata


Skor dengan nilai 64,7 persen disertai indikator tren turun dari 68,7 menjadi 56,7 persen, kartu Tanaman Teratas yang menampilkan Jeruk sebagai komoditas paling sering dianalisis, serta kartu Lokasi Aktif dengan nilai 9 wilayah berbeda.

Panel Analisis per Hari menampilkan bar chart vertikal berwarna hijau yang memvisualisasikan distribusi jumlah analisis harian selama periode 30 hari dari tanggal 12 April hingga 12 Mei 2026, dengan puncak tertinggi sebesar 4 analisis pada sekitar tanggal 16 April dan beberapa hari tanpa aktivitas sama sekali. Bagian bawah tab menampilkan dua panel visualisasi berdampingan, yaitu pie chart Distribusi Skor Kesesuaian yang memperlihatkan proporsi masing-masing kategori Optimal, Waspada, Kurang Sesuai, dan Sangat Optimal menggunakan warna yang konsisten dengan sistem kode warna seluruh platform, serta grouped bar chart Perbandingan Periode yang membandingkan distribusi skor antara Periode Lalu dan Periode Ini secara visual. Panel Ekspor Data di bagian paling bawah halaman menyediakan dua tombol yaitu Export CSV untuk keperluan analisis lanjutan menggunakan perangkat lunak spreadsheet dan Cetak atau PDF untuk keperluan pelaporan formal yang memerlukan format tetap dan tidak dapat dimodifikasi.



Gambar 4.9. Tampilan Executive Dashboard Tab Performance Overview

4.9.3. Tab Data Explorer



Gambar 4.10. Tampilan Executive Dashboard Tab Data Explorer

Tab Tab Data Explorer merupakan tab kedua yang dapat diakses oleh kedua tingkatan administrator dan berfungsi sebagai jendela eksplorasi visual langsung terhadap data yang tersimpan dalam Data Warehouse sistem AgroSense. Panel pertama berlabel Rata-rata Kondisi per Tanaman menampilkan bar chart dengan delapan batang yang masing-masing mewakili satu jenis tanaman dengan warna yang unik dan berbeda, yaitu merah untuk tomato, cokelat-oranye untuk potato, hijau tua untuk maize, hijau muda untuk mungbean, kuning-oranye untuk banana, biru cyan untuk watermelon, oranye untuk orange, dan ungu muda untuk papaya. Grafik dilengkapi dropdown di sudut kanan atas yang memungkinkan administrator mengubah parameter yang ditampilkan antara Suhu, Kelembapan, dan pH, dengan pilihan aktif pada screenshot adalah Suhu yang menunjukkan bahwa papaya memiliki rata-rata suhu tertinggi sementara maize berada di rentang paling moderat di antara kedelapan tanaman tersebut.


Panel kedua berlabel Zona Kondisi Optimal per Tanaman menampilkan delapan kartu ringkasan dalam tata letak grid empat kolom dua baris, masing-masing memuat rentang nilai Suhu, Kelembapan, dan pH Tanah untuk satu jenis tanaman berdasarkan

seluruh skenario yang tersimpan dalam Data Warehouse. Data yang ditampilkan mencakup Tomato dengan 3.652 skenario menunjukkan rentang suhu 0,4 hingga 51,7 derajat Celsius, kelembapan 48,3 hingga 80 persen, dan pH 5,5 hingga 8; Potato dengan 3.652 skenario menunjukkan rentang suhu negatif 0,7 hingga 49,2 derajat Celsius, kelembapan 50,8 hingga 80 persen, dan pH 5,5 hingga 8; Maize dengan 100 skenario menunjukkan rentang suhu 18 hingga 26,5 derajat Celsius, kelembapan 55,3 hingga 74,8 persen, dan pH 5,5 hingga 7; Mungbean dengan 100 skenario menunjukkan rentang suhu 27 hingga 29,9 derajat Celsius, kelembapan 80 hingga 90 persen, dan pH 6,2 hingga 7,2; Banana dengan 100 skenario menunjukkan rentang suhu 25 hingga 29,9 derajat Celsius, kelembapan 75 hingga 85 persen, dan pH 5,5 hingga 6,5; Watermelon dengan 100 skenario menunjukkan rentang suhu 24 hingga 27 derajat Celsius, kelembapan 80 hingga 90 persen, dan pH 6 hingga 7; Orange dengan 100 skenario menunjukkan rentang suhu 10 hingga 34,9 derajat Celsius, kelembapan 90 hingga 95 persen, dan pH 6 hingga 8; serta Papaya dengan 100 skenario menunjukkan rentang suhu 23 hingga 43,7 derajat Celsius, kelembapan 90 hingga 94,9 persen, dan pH 6,5 hingga 7.



Gambar 4.11. Tampilan Executive Dashboard Tab Data Explorer

4.9.4. Tab User Management (Superadmin Only)



Gambar 4.12. Tampilan Executive Dashboard Tab User Management

Tab User Management merupakan tab ketiga yang bersifat eksklusif dan hanya dapat diakses oleh pengguna dengan peran superadmin. Halaman ini menampilkan antarmuka pengelolaan akun administrator dalam format tabel yang bersih dan fungsional. Bagian atas halaman menampilkan informasi jumlah total akun aktif yaitu 2 admin dan superadmin di sisi kiri, serta dua tombol aksi di sisi kanan yaitu tombol Tambah Akun berwarna kuning-hijau untuk menambahkan akun administrator baru ke dalam sistem dan tombol Segarkan berwarna putih untuk memperbarui daftar yang ditampilkan tanpa harus me-reload seluruh halaman. Tabel di bawahnya memiliki empat kolom yaitu Nama, Email, Role, dan Aksi, yang menyajikan seluruh informasi penting mengenai masing-masing akun administrator dalam satu tampilan yang kompak.

Dari data yang tersedia pada screenshot, terdapat dua akun administrator aktif dalam sistem AgroSense. Baris pertama menampilkan akun Super Admin dengan alamat email super@admin.com yang memiliki peran superadmin ditandai dengan badge berwarna merah muda. Baris kedua menampilkan akun Rama dengan alamat email dhaniramaaa533@gmail.com yang memiliki peran admin ditandai dengan badge berwarna kuning-hijau. Kolom Aksi pada setiap baris menyediakan dua elemen interaktif yaitu dropdown berlabel Ubah ke yang memungkinkan superadmin mengubah peran akun antara superadmin dan admin secara langsung, serta tombol Hapus berwarna merah untuk menghapus akun administrator dari sistem. Kombinasi fitur perubahan peran dan penghapusan akun yang tersedia langsung dalam antarmuka tabel ini memungkinkan pengelolaan akun yang efisien tanpa harus berpindah ke halaman atau dialog terpisah

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Sistem AgroSense berhasil dirancang dan diimplementasikan sebagai platform Business Intelligence perkebunan berbasis web yang secara penuh mengintegrasikan Data Warehouse berskema bintang, model Machine Learning Random Forest Classifier dengan akurasi 80,625 persen, dan data cuaca real-time dari API BMKG dalam satu antarmuka terpadu yang dapat diakses oleh petani, penyuluh perkebunan, maupun pemangku kebijakan sektor agrikultur. Data Warehouse yang dibangun menghasilkan tiga tabel dimensi yaitu `dim_crop` dengan delapan entitas tanaman, `dim_weather` dengan 7.904 rekaman kondisi cuaca, dan `dim_soil` dengan 605 rekaman kondisi tanah, serta satu tabel fakta `fact_prediction` dengan 7.904 rekaman tanpa nilai kosong, yang keseluruhannya diperoleh melalui proses ETL terhadap dua dataset Kaggle berjumlah lebih dari 38.000 rekaman mentah. Model Random Forest yang dilatih menggunakan fitur suhu, kelembapan, dan pH tanah menunjukkan performa tinggi pada enam dari delapan kelas tanaman dengan F1-score di atas 0,85, sementara kelas tomato dan potato menunjukkan F1-score lebih rendah akibat kemiripan karakteristik agroklimat keduanya sebagai sesama anggota famili Solanaceae. Platform AgroSense terdiri dari tujuh halaman untuk pengguna umum dan satu Executive Dashboard dengan sistem RBAC dua tingkat untuk administrator, dilengkapi fitur prakiraan kesesuaian tiga hari ke depan, citra satelit Himawari-9 real-time, insight agronomi otomatis, serta ekspor data dalam format JSON dan CSV, yang secara keseluruhan membuktikan bahwa pendekatan Business Intelligence memiliki potensi transformatif yang sangat nyata dan signifikan di sektor perkebunan Indonesia.

5.2. Saran

Pengembangan sistem AgroSense ke depan disarankan untuk memperluas cakupan tanaman dengan menambahkan komoditas strategis Indonesia seperti padi, singkong, dan kedelai melalui kolaborasi dataset dengan Kementerian Perkebunan atau Balitbangtan, meningkatkan akurasi model dengan menambahkan fitur prediktor seperti kandungan nutrisi tanah dan ketinggian wilayah serta mengeksplorasi algoritma lanjutan seperti

XGBoost atau teknik oversampling SMOTE untuk mengatasi ketidakseimbangan kelas antara tomato dan potato, serta mengembangkan aplikasi mobile native yang mendukung notifikasi push peringatan cuaca ekstrem dan akses data secara offline sehingga sistem dapat menjangkau petani di daerah terpencil dengan keterbatasan konektivitas internet..

DAFTAR PUSTAKA

1. Ajzen, I., & Fishbein, M. (1975). *Belief, attitude, intention, and behavior: An introduction to theory and research*. Reading MA: Addison-Wesley.
2. Arning, K., & Ziefle, M. (2007). Understanding age differences in PDA acceptance and performance. *Computers in Human Behavior* 23, 2904–2927.
3. Astrachan, C. B., Patel, V. K., & Wanzenried, G. (2014). A comparative study of CB-SEM and PLS-SEM for theory development. *Journal of Family Business Strategy* 5, 116–128.
4. Adamson, C. (2010). *Star Schema: The Complete Reference*. McGraw-Hill Osborne Media.
5. Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>
6. Asosiasi Penyelenggara Jasa Internet Indonesia. (2023). *Laporan Survei Penetrasi Internet Indonesia 2023*. APJII.
7. Bargas-Avila, J. A., & Hornbæk, K. (2011). Old wine in new bottles or novel challenges? A critical analysis of empirical studies of user experience. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, 2689–2698. <https://doi.org/10.1145/1978942.1979336>
8. Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
9. Food and Agriculture Organization of the United Nations. (2021). *The State of Food and Agriculture 2021: Making Agrifood Systems More Resilient to Shocks and Stresses*. FAO. <https://doi.org/10.4060/cb4476en>
10. Google. (2021). Core Web Vitals. <https://web.dev/vitals/>
11. Hatfield, J. L., & Prueger, J. H. (2015). Temperature extremes: Effect on plant growth and development. *Weather and Climate Extremes*, 10, 4–10. <https://doi.org/10.1016/j.wace.2015.08.001>
12. Kementerian Perkebunan Republik Indonesia. (2022). *Statistik Perkebunan 2022*. Pusat Data dan Sistem Informasi Perkebunan, Kementan RI.

13. Ambarwari, A., Widyawati, D. K., & Wahyudi, A. (2021). Sistem Pemantau Kondisi Lingkungan Perkebunan Tanaman Pangan dengan Internet of Things. *Jurnal Rekayasa Sistem dan Teknologi Informasi*, 1(10), 496–503.
14. Alfianto, R. (2024). Klasifikasi Tanaman Pangan Berdasarkan Kondisi Lahan perkebunan Menggunakan Metode Random Forest [Tugas Akhir, Universitas Trunojoyo Madura]. Repositori Universitas Trunojoyo.
15. Badan Meteorologi, Klimatologi, dan Geofisika. (2023). Layanan Data dan Informasi Cuaca BMKG melalui Application Programming Interface (API) Publik. BMKG Republik Indonesia. <https://data.bmkg.go.id>
16. Badan Pusat Statistik. (2023). Statistik Indonesia 2023. BPS Republik Indonesia. <https://www.bps.go.id>
17. Darman, R. (2018). Analisis Visualisasi dan Pemetaan Data Tanaman Padi. *Jurnal Ilmiah Rekayasa dan Manajemen Sistem Informasi*, 4(2), 156–162.
18. Dwiyatno, S., Krisnaningsih, E., Hidayat, D. R., & Sulistiyono. (2022). Smart Agriculture Monitoring Penyiraman Tanaman Berbasis Internet of Things. *PROSISKO: Jurnal Pengembangan Riset dan Observasi Sistem Komputer*, 9(1), 38–43. <https://doi.org/10.30656/prosisko.v9i1.4669>